



上海大学

SHANGHAI UNIVERSITY

本科毕业论文（设计）

UNDERGRADUATE THESIS (PROJECT)

题 目： 基于机器学习的物联网入侵检测

学 院： 中欧工程技术学院

专 业： 信息工程

学 号： 22124700

学生姓名： 丁志成

指导教师： 孙轲

起讫日期： 2026.1.19--2026.5.29



姓 名：丁志成

学号：22124700

论文题目：《基于机器学习的物联网入侵检测》

原创性声明

本人声明：所呈交的论文是本人在指导教师指导下进行的研究工作。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已发表或撰写过的研究成果。参与同一工作的其他同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名：_____日 期：_____

本论文使用授权说明

本人完全了解上海大学有关保留、使用学位论文的规定，即：学校有权保留论文及送交论文复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容。

（保密的论文在解密后应遵守此规定）

签 名：_____指导教师签名：_____日期：_____

摘 要

随着物联网（Internet of Things, IoT）、工业物联网（Industrial Internet of Things, IIoT）与边缘计算的持续发展，入侵检测系统（Intrusion Detection System, IDS）需要在噪声扰动、字段缺失和联合输入退化条件下保持稳定识别能力。针对干净测试集高精度模型鲁棒性不足的问题，本文基于 Edge-IIoTset 数据集，开展了相关测试，并以卷积神经网络（Convolutional Neural Network, CNN）、长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环单元（Gated Recurrent Unit, GRU）组成的 CNN-LSTM-GRU 模型作为基线模型，开展了如下研究工作：

1）本文首先进行了一系列压力测试，实验结果表明，基线模型在干净测试集上仅出现 3 条正常流量误报，攻击样本漏检数为 0；在类别漂移测试中，平衡准确率保持在 99.9991%—100% 之间。但在输入退化条件下，基线模型性能显著下降：当高斯噪声标准差由 0.3 增至 0.7 时，准确率由 99.574% 降至 72.101%，平衡准确率由 99.704% 降至 80.527%，精确率降至 50.141%；当特征缺失率达到 0.7 时，准确率为 88.598%，平衡准确率为 79.989%，攻击召回率降至 60.372%，漏报率升至 39.628%。上述结果说明，噪声扰动主要引发误报增加，特征缺失主要造成攻击漏检增加。

2）为提升模型在复杂输入条件下的稳定性，本文在基线模型基础上设计了四种鲁棒性增强方案，分别从缺失掩码编码、噪声增强训练、特征重权和一致性约束等角度改进模型对退化输入的适应能力，并通过软投票策略对不同方案的输出结果进行融合。实验结果显示，四方案软投票模型在特征缺失场景中取得 99.697% 的最优平均平衡准确率，在噪声场景中保持 99.892% 的平均平衡准确率，说明多种增强策略的组合能够改善模型在异常输入条件下的稳定性。

3）本文进一步将多模块机制压缩为单模型端到端结构，提出掩码引导可靠性表示门控（Mask-guided Reliability Representation Gating, MR²G）和原型引导可靠性门控（Prototype-Guided Reliability Gating, PGRG）。在统一条件的联合扰动下，PGRG 的联合扰动平均平衡准确率达到 99.635%，高于四模块软投票模型的 99.345%。资源开销方面，四模块软投票模型平均测试时间为 690.450 s，而 MR²G 与 PGRG 分别为 142.066s 和 142.062s，测试时间均降低 79.420%；MR²G 和 PGRG 参数量分别为 134907 和 226718。研究表明，PGRG 在鲁棒性、轻量化之间取得了更优综合平衡。

关键词：物联网入侵检测；鲁棒性；边缘部署；可靠性门控

ABSTRACT

With the continuous development of the Internet of Things (IoT), Industrial Internet of Things (IIoT), and edge computing, intrusion detection systems (IDSs) are required to maintain stable recognition capability under noisy perturbations, missing fields, and jointly degraded inputs. To address the insufficient robustness of high-accuracy models on clean test sets, this thesis constructs experiments. A hybrid Convolutional Neural Network-Long Short-Term Memory-Gated Recurrent Unit (CNN-LSTM-GRU) model is adopted as the baseline model. The main research work is as follows:

1) This article first conducted a series of stress tests, whose results show that the baseline model produces only three false positives for normal traffic and no missed attack samples on the clean test set. Under class-ratio tests, its balanced accuracy remains between 99.9991% and 100%. However, the model exhibits substantial degradation under non-ideal inputs. When the Gaussian noise standard deviation increases from 0.3 to 0.7, accuracy decreases from 99.574% to 72.101%, balanced accuracy decreases from 99.704% to 80.527%, and precision decreases to 50.141%. When the feature missing rate reaches 0.7, accuracy, balanced accuracy, attack recall, and miss detection rate are 88.598%, 79.989%, 60.372%, and 39.628%, respectively. These results indicate that noise mainly increases false alarms, whereas feature missing mainly increases missed attack detections.

2) To improve the stability of the model under complex input conditions, this thesis designs four robustness-enhancement schemes based on the baseline model. These schemes improve the model's adaptability to degraded inputs from the perspectives of missing-mask encoding, noise-augmented training, feature reweighting, and consistency constraints. In addition, a soft-voting strategy is adopted to fuse the outputs of different schemes. The experimental results show that the four-scheme soft-voting model achieves the best average balanced accuracy of 99.697% in feature-missing scenarios and maintains an average balanced accuracy of 99.892% in noisy scenarios. These results indicate that the combination of multiple enhancement strategies can improve the stability of the model under abnormal input conditions.

3) Furthermore, the multi-module mechanism is compressed into a single end-to-end model. Two modules are proposed: Mask-guided Reliability Representation Gating (MR²G) and Prototype-Guided Reliability Gating (PGRG). Under joint perturbations with unified experimental conditions, PGRG achieves an average balanced accuracy of 99.635%, which is higher than the 99.345% achieved by the four-module soft-voting model. In terms of computational cost, the average testing time of the four-module soft-voting model is 690.450 s, while those of MR²G and PGRG are 142.066 s and 142.062 s, respectively, both reducing

the testing time by 79.420%. The parameter counts of MR²G and PGRG are 134,907 and 226,718, respectively. The results demonstrate that PGRG achieves a better overall balance between robustness and lightweight design.

Keywords: IoT intrusion detection; robustness; edge deployment; prototype-guided reliability gating

目 录

摘 要.....I

1 绪论..... 1

1.1 研究背景 1

1.2 国内外研究现状 2

1.2.1 物联网入侵检测数据集研究现状..... 2

1.2.2 传统机器学习入侵检测研究现状..... 3

1.2.3 深度学习入侵检测研究现状..... 3

1.2.4 轻量化与边缘部署研究现状..... 4

1.2.5 鲁棒性与异常输入条件研究现状..... 5

1.3 主要研究内容和研究目标 6

1.4 本论文主要结构 7

2 相关技术介绍..... 9

2.1 相关指标说明 9

2.2 CNN-LSTM-GRU 相关技术 11

2.2.1 卷积神经网络..... 11

2.2.2 长短期记忆网络..... 13

2.2.3 门控循环单元..... 13

2.2.4 CNN-LSTM-GRU 混合模型技术..... 14

2.3 鲁棒表示学习技术 15

2.3.1 去噪自编码器..... 15

2.3.2 数据增强..... 16

2.3.3 一致性约束..... 16

2.3.4 可靠性门控机制..... 17

2.3.5 原型学习..... 17

2.3.6 四鲁棒模块技术原理..... 18

2.4 本章小结 19

3 基于 CNN-LSTM-GRU 的四模块优化软投票模型..... 20

3.1 引言	20
3.2 基线模型压力测试和性能退化测试	20
3.2.1 普通环境下的基线检测性能	20
3.2.2 基线模型在类别漂移下的性能表现	21
3.2.3 基线模型在噪声扰动下的性能退化	21
3.2.4 基线模型在特征缺失下的性能退化	22
3.2.5 性能退化原因分析	23
3.3 四模块软投票模型	23
3.3.1 抗特征缺失模块	24
3.3.2 抗噪声干扰模块	24
3.3.3 噪声与缺失联合增强策略	25
3.3.4 四模块软投票集成策略	26
3.4 实验结果及分析	27
3.4.1 实验设置	27
3.4.2 消融实验	28
3.4.3 基于 TensorFlow 的对照模型对比实验	29
3.5 本章小结	31
4 基于单模型结构的鲁棒性改进	32
4.1 引言	32
4.2 单模型改进结构设计	32
4.2.1 基于缺失掩码的可靠性门控结构	32
4.2.2 基于类别原型的可靠性门控结构	33
4.2.3 单鲁棒模型设计思路	35
4.3 实验结果及分析	36
4.3.1 实验设置	36
4.3.2 新模块与四模块软投票模型的性能对比实验	37
4.3.3 新模块与四模块软投票模型的参数对比	38
4.3.4 MR ² G 与 PGRG 的内部机制对比	40
4.3.5 本地推理部署可行性分析	41
4.4 本章小结	44
5 总结与展望	45

5.1 工作总结	45
5.2 未来展望	46
参考文献.....	48
致 谢	51

1 绪论

1.1 研究背景

随着物联网（Internet of Things, IoT）、工业物联网（Industrial Internet of Things, IIoT）、边缘计算和智能终端的发展，网络空间中的设备数量、协议类型和业务链路持续增加。物联网系统通常由传感器、边缘网关、工业控制设备、云平台和业务应用共同构成，设备异构性和通信链路复杂性使其面临拒绝服务、扫描探测、恶意代码传播、注入攻击和中间人攻击等安全威胁^[1-2]。因此，构建能够识别异常流量和攻击行为的入侵检测方法，对于提升物联网系统运行安全性有实际意义。

入侵检测系统（Intrusion Detection System, IDS）是网络安全防护体系中的重要组成部分。传统基于规则和特征库的检测方法实现较为直接，但其检测效果依赖已知攻击特征，在面对未知攻击、变种攻击和复杂流量模式时容易受到限制^[3]。近年来，机器学习和深度学习方法被应用于入侵检测任务，其中，卷积神经网络（Convolutional Neural Network, CNN）、循环神经网络（Recurrent Neural Network, RNN）、自编码器（Auto-Encoder, AE）和注意力机制等模型能够从流量特征中学习判别信息，为物联网流量检测提供了数据驱动的建模方式^[4]。

需要注意的是，公开数据集上的较高准确率并不必然代表模型在真实部署环境下具有同等稳定性。边缘采集、协议解析、设备通信和多源日志融合过程中，流量特征可能受到数值噪声、采集漂移、字段缺失和数据格式不一致等因素影响。相关研究表明，扰动输入可能改变基于机器学习的网络入侵检测模型输出，缺失数据也会影响检测模型对正常流量和攻击流量的判别能力^[5-6]。因此，对模型在噪声和缺失条件下的性能变化进行分析，比单独报告干净测试集准确率更能反映模型的实际适用性。

基于上述问题，本文将研究重点放在复杂输入条件下的物联网入侵检测实验验证。本文以卷积神经网络-长短期记忆网络-门控循环单元混合模型（Convolutional Neural Network-Long Short-Term Memory-Gated Recurrent Unit, CNN-LSTM-GRU）作为基线模型，按照统一的数据划分完成二分类建模^[7]；随后设计高斯噪声扰动、随机特征缺失和联合扰动测试，用于观察基线模型在非理想

输入条件下的性能变化；在此基础上，结合去噪自编码、一致性约束和原型学习等思想，构建若干鲁棒优化模块并进行对比实验^[8-10]。

1.2 国内外研究现状

随着物联网和工业物联网应用场景增多，物联网入侵检测逐渐成为网络安全研究中的一个重要方向。公开数据集与对比实验表明，不同 IoT/ IIoT 入侵检测模型在攻击类别、数据分布和部署场景变化下会表现出差异^{[1][2]}。因此，本文从数据集、模型结构、轻量化部署和鲁棒性评价几个方面梳理相关研究，为后续实验设计提供依据。

从研究对象看，IoT/ IIoT 入侵检测既涉及通用网络入侵检测中的分类、误报和漏报问题，也涉及工业现场设备异构、资源受限和数据质量不稳定等具体约束^[2-3]。因此，本文在综述中不追求覆盖所有网络安全方向，而是重点梳理与本文模型设计直接相关的数据集、机器学习方法、深度学习方法、边缘部署和异常输入鲁棒性研究。

1.2.1 物联网入侵检测数据集研究现状

物联网入侵检测模型的发展首先依赖于公开数据集。早期网络入侵检测研究主要使用 KDD99、NSL-KDD、UNSW-NB15 和 CICIDS 等通用网络安全数据集，这些数据集推动了入侵检测算法的发展，但其网络环境、协议类型和攻击模式与真实 IoT/ IIoT 场景存在差异^[3]。近年来，研究人员开始构建更贴近物联网和工业物联网场景的数据集，其中 Edge-IIoTset（面向边缘计算场景的 IoT/ IIoT 安全数据集）覆盖正常流量和多类攻击流量，能够支持集中式学习和联邦学习等实验设置^{[1][11]}。

Edge-IIoTset 面向 IoT 与 IIoT 应用构建，包含来自多个物联网设备和边缘节点的流量数据，适合用于研究边缘计算和工业物联网场景下的入侵检测问题^[1]。与只关注单一网络环境的数据集相比，该数据集在设备类型、攻击类别和协议特征方面更贴近本文研究对象。

已有研究还基于 Edge-IIoT 相关数据开展不同入侵检测模型的对比评价，结果显示不同模型在准确率、泛化能力和类别不平衡条件下的表现并不完全一致^[11]。这说明在选择数据集后，仍需要保持统一的数据划分和评价指标，才能较为客观

地比较不同模型或模块的效果。

基于上述原因，本文选择 Edge-IIoTset 作为基础数据集，并在同一预处理流程下进行基线模型、鲁棒模块和单模块结构的对比实验，主要关注在既定公开数据集上验证模型在噪声扰动和特征缺失条件下的性能变化。

1.2.2 传统机器学习入侵检测研究现状

在深度学习方法广泛应用之前，传统机器学习一直是入侵检测的重要技术路线。常用方法包括决策树、随机森林、支持向量机、K 近邻、朴素贝叶斯、逻辑回归和集成学习等。这类方法通常先对网络流量进行特征提取、特征选择和归一化处理，再通过分类器完成正常流量与攻击流量的区分^[3]。

在 IoT 入侵检测场景中，传统机器学习方法具有训练速度较快、模型结构相对清晰和部署成本较低等优点。基于 Edge-IIoT 数据集的对比研究表明，数据驱动方法能够用于物联网安全检测，但不同模型在复杂攻击类别和类不平衡场景下仍存在性能差异^[11]。

国内研究也从多个角度讨论了入侵检测模型的适用性。蹇诗婕等指出，复杂网络环境下入侵检测仍面临泛化能力、实时性和复杂攻击识别等问题^[3]；张吕军研究了基于深度迁移学习的物联网入侵检测框架，关注不同环境之间的模型迁移问题^[12]；魏明锐从可解释学习角度研究物联网安全通用入侵检测系统，说明模型解释性也是物联网安全检测中的重要因素^[13]；吕正林等研究了边云协同环境下智能家居物联网入侵检测方法，体现出国内研究对边缘侧检测和云端协同分析的关注^[14]。

总体来看，传统机器学习方法实现成本较低，但通常依赖人工特征工程，模型性能容易受到特征选择、数据分布和预处理方式影响。当 IoT/ IIoT 流量呈现高维、多源和时序相关等特点时，传统方法对深层特征交互和动态流量模式的表达能力相对有限。因此，本文后续主要关注能够学习特征表示的深度学习方法。

1.2.3 深度学习入侵检测研究现状

深度学习方法能够通过多层非线性结构自动提取流量特征，在物联网入侵检测中得到广泛应用。卷积神经网络（Convolutional Neural Network, CNN）能够捕获局部特征组合关系，长短期记忆网络（Long Short-Term Memory, LSTM）和

门控循环单元（Gated Recurrent Unit, GRU）能够建模序列依赖，自编码器可用于异常表示学习，Transformer 类模型则可增强表格特征之间的上下文建模能力[16-19]。

自编码器相关研究表明，通过重建误差或潜在表示可以刻画正常行为与异常行为之间的差异^[8]。Tab Transformer 等模型进一步说明，针对表格特征的上下文嵌入建模能够提升对复杂特征交互的表达能力，并对缺失和噪声特征具有一定鲁棒性^[19]。这些研究为本文后续采用去噪重建和可靠性表示提供了参考。

在混合神经网络方面，CNN 与 LSTM、GRU 的结合被广泛用于网络流量建模。Kilichev 等将 CNN、LSTM 和 GRU 结合用于 IoT 电动汽车充电站（Electric Vehicle Charging Station, EVCS）入侵检测任务，说明卷积特征提取与时序依赖建模可以形成互补^[7]。Nazre 等提出基于时序卷积网络（Temporal Convolutional Network, TCN）的入侵检测方法，在 Edge-IIoTset 数据集上报告了较高准确率，并与 1D-CNN、CNN-LSTM、CNN-GRU、CNN-BiLSTM 和 CNN-GRU-LSTM 等模型进行了对比^[20]。国内也有研究将随机森林特征选择与 LSTM 结合用于网络流量异常识别，说明深度时序模型在流量检测任务中具有一定适配性^[15]。

注意力机制也是近年来 IoT 入侵检测研究中的常见改进方向。Naeem 等提出改进的 Attention-CNN-BiLSTM 架构，将 CNN、BiLSTM 和注意力机制结合用于 IoT 僵尸网络检测^[21]；Ishtiaq 等提出 CST-AFNet，将多尺度 CNN、BiGRU 和双注意力机制结合用于 IoT 网络入侵检测^[22]。这些研究说明，特征提取、时序建模和注意力筛选的融合，是提升模型检测能力的一种常见思路。

综上，深度学习研究已经从单一 CNN 或 RNN 模型逐渐发展为 CNN-RNN 混合结构、TCN、Transformer、注意力机制和自编码器等多机制融合模型^[7,19-22]。不过，现有不少研究主要报告干净测试集或常规划分下的分类结果，对噪声扰动、特征缺失和联合扰动下的性能退化分析仍相对有限。本文后续实验正是围绕这一问题展开，而不是对所有模型结构进行无差别扩展。

1.2.4 轻量化与边缘部署研究现状

由于物联网终端和边缘设备通常计算能力有限、存储空间受限，入侵检测模型不仅需要关注检测准确率，也需要考虑推理延迟、参数量和部署复杂度。因此，轻量化模型和边缘部署是物联网入侵检测研究中的重要方向^[2]。

Hasan 等提出面向 IIoT 的轻量型自编码器特征学习方法,通过特征压缩和模型简化降低部署开销^[23]。吕正林等研究了边云协同环境下的智能家居物联网入侵检测方法,通过边缘侧初步检测与云端分析协同提升系统适应性^[14]。此外,联邦学习也被用于工控入侵检测模型训练,以缓解工业控制网络中多源数据难以集中共享的问题^[24]。

轻量化研究通常从模型压缩、参数裁剪、浅层网络设计、知识蒸馏和特征选择等角度展开。因此,本文的轻量化并不是单纯追求极低参数量,而是在保持检测性能和鲁棒性的前提下,尝试将多模块机制压缩为单一段到端结构,使其更适合后续端侧推理和可视化部署。

1.2.5 鲁棒性与异常输入条件研究现状

已有物联网安全研究指出,物联网系统的安全风险与设备异构、网络连接复杂和资源受限等因素有关^[30],鲁棒性研究关注模型在输入被污染、不完整或分布发生变化时是否仍能保持较稳定的检测结果。现有 IoT/IIoT 数据集和深度模型研究通常能在干净测试集上取得较高准确率,但真实边缘采集链路中可能存在传感噪声、通信抖动、协议解析误差、字段缺失、监测节点失效和跨设备分布漂移等异常输入条件^{[2][3]}。相关研究也指出,扰动输入和对抗样本会影响基于机器学习的网络入侵检测模型稳定性^[5]。

在噪声扰动与对抗扰动方面,网络流量属于结构化数据,部分可变流量特征可能因攻击规避、采样误差或网关差异产生数值偏移,从而导致样本偏离训练分布。相关综述指出,基于机器学习的网络入侵检测系统 (Network Intrusion Detection System, NIDS) 虽然能够捕获复杂特征关系,但仍容易受到异常扰动输入影响;也有研究从对抗训练、特征工程、样本均衡、集成学习和模型微调等角度提出防御框架^{[5][25]}。

在特征缺失与不完整输入方面,研究重点主要集中在缺失值补全、掩码建模和缺失感知学习。IDS 数据中的缺失可能来自流量采集丢包、字段解析失败、多源日志对齐不一致或设备离线。Tahir 等针对 IDS 数据提出缺失数据处理方法,将随机缺失模拟、堆叠去噪自编码器和梯度提升相结合,说明高比例缺失会影响检测性能,而合理插补有助于提升分类器鲁棒性^[6]。在更一般的表格数据研

究中，ReMasker 通过对缺失值之外的单元再次随机遮蔽来训练 masked autoencoder，以学习缺失不变表示^[26]。

除直接补全外，异常检测领域还出现了“掩码建模—相关性学习”的研究路线。掩码单元建模（Masked Cell Modeling, MCM）将掩码建模方法用于表格异常检测，强调通过捕获特征之间的内在相关性判断样本是否偏离正常模式^[27]。这一思路对物联网入侵检测具有启发意义：当部分字段缺失或受噪声污染时，模型可以利用剩余可靠字段之间的相关关系形成较稳定的表示。

在鲁棒训练策略方面，数据增强、一致性正则和集成学习是较常见的技术路径。噪声增强和随机特征丢弃可在训练阶段主动构造受扰样本；一致性正则要求同一样本在干净输入和受扰输入下保持相近预测，从而减少扰动造成的表示漂移^[9]。本文第三章中的四模块软投票模型即属于对多种鲁棒策略进行组合验证的实验性方案。

在异常输入与真实攻击异常的区分方面，原型学习和可靠性判别为模型设计提供了参考。原型网络通过样本到类别原型的距离完成分类^[10]；分布原型扩散学习（Distribution Prototype Diffusion Learning, DPDL）利用多原型刻画正常样本紧凑分布并拉开异常样本距离^[28]；基于原型的异常检测方法（Prototype-based Anomaly Detection, Pro-AD）进一步通过原型约束避免异常样本被过度重建为正常模式^[29]。这些研究说明，仅做输入修复可能不足以保证检测稳定性，还需要考虑表示空间中正常样本与攻击样本的区分。

结合上述研究现状可以看出，物联网入侵检测仍存在两个与本文直接相关的问题：一是高精度模型在噪声和缺失条件下可能出现不同类型的退化；二是多模块鲁棒方法虽然有效，但部署成本较高。本文后续提出的四模块鲁棒优化以及两个新的单模型结构，正是围绕这两个问题展开。

1.3 主要研究内容和研究目标

本文面向物联网与工业物联网入侵检测中的输入数据退化问题，重点研究噪声扰动、特征缺失以及二者共同作用下模型检测性能的稳定性。总体目标是：在统一数据划分、特征选择和标准化协议下，构建物联网入侵检测基线模型，通过压力测试找出高精度模型在非理想输入条件下的退化方式，并进一步设计鲁棒增

强机制和轻量化单模型结构，使模型在复杂部署环境中兼顾检测准确率、鲁棒性和端侧可部署性。

本文首先构建统一实验协议下的物联网入侵检测基线模型，通过普通环境下的测试结果，首先验证基线模型在干净测试集上的检测能力，为后续鲁棒性压力测试和模型优化提供统一参照。第二，设计高斯噪声与随机特征缺失两类压力测试机制，用于识别基线模型在复杂输入条件下的性能退化的临界点。第三，在性能退化分析的基础上，围绕特征缺失和噪声扰动设计若干鲁棒性增强方案，包括缺失掩码编码、噪声增强训练、特征重权和一致性约束等方法，并通过软投票方式进行组合对比。第四，针对多方案集成模型推理开销较大的问题，进一步尝试构建单模型改进结构，引入缺失掩码和类别原型信息，对输入退化条件下的特征可靠性进行建模。第五，通过参数量、测试时间和本地推理实验，对改进模型的轻量化和部署可行性进行分析。

与仅报告普通测试集准确率的入侵检测研究相比，本文更关注模型在复杂输入退化条件下的输出稳定性，并尝试给出一条从压力测试诊断、多模块鲁棒增强到单模型压缩部署的实验路径。

1.4 本论文主要结构

本文共分为五个章节，各个章节的内容安排如下：

第一章为绪论。本章主要阐述物联网与工业物联网场景下入侵检测研究的背景与意义，分析真实部署环境中噪声扰动、字段缺失、采集漂移和多源数据不一致等问题对模型稳定性的影响；同时梳理物联网入侵检测数据集、传统机器学习方法、深度学习方法、轻量化部署和鲁棒性研究现状，并在此基础上明确本文的研究目标、研究内容和章节安排。

第二章为相关技术介绍。本章首先介绍本文使用的 Edge-IloTset 数据集及其适用场景，然后说明 CNN、LSTM、GRU 以及 CNN-LSTM-GRU 混合模型的基本原理；进一步介绍去噪自编码器、数据增强、一致性约束、可靠性门控、原型学习、四鲁棒模块等鲁棒表示学习相关技术，为后续模型设计提供理论基础。

第三章为基于 CNN-LSTM-GRU 的四模块优化软投票模型。本章首先构建 CNN-LSTM-GRU 基线模型，并在普通环境、类别比例变化、噪声扰动和特征缺

失条件下进行压力测试，诊断高精度基线模型在复杂输入退化条件下的性能退化；随后设计抗特征缺失模块、抗噪声干扰模块和双鲁棒联合模块，并通过四个成员模块的软投票策略形成集成优化模型，最后通过消融实验和对照模型实验验证四模块软投票模型的综合鲁棒性。

第四章为基于四模块软投票机制的新模型设计。本章针对四模块集成模型推理链路较长和端侧部署复杂度较高的问题，进一步从多模块鲁棒机制中凝练单模块结构 MR²G（Mask-guided Reliability Representation Gating，掩码引导可靠性表示门控）和 PGRG（Prototype-Guided Reliability Gating，原型引导可靠性门控），提出掩码引导可靠性表示门控模块，并在此基础上设计原型引导可靠性门控模块；通过联合扰动实验、参数量对比、内部机制验证和端侧推理实验，分析新增单模块在鲁棒性、轻量化和可部署性之间的平衡效果。

第五章为总结与展望。本章对全文研究工作进行总结，概括本文在压力测试诊断、鲁棒机制增强、单模块压缩和端侧部署验证方面的主要成果，分析当前研究仍存在的数据场景、在线自适应、安全鲁棒性和真实端侧部署不足，并对后续研究方向进行展望。

2 相关技术介绍

2.1 相关指标说明

本文实验使用 Edge-IIoTset 数据集作为基础数据源。Edge-IIoTset 是一个专门针对 IoT、IIoT 和边缘计算环境设计的公开数据集。该数据集模拟了典型的 IoT 与边缘计算场景，并包含了丰富的流量数据、设备行为日志以及攻击模式。该数据集面向 IoT 与 IIoT 安全场景构建，有来自多个 IoT 设备和边缘节点的数据流，涵盖了正常操作条件下的通信流量以及多种类型的网络攻击(如 DDoS、恶意软件传播、注入攻击等)，便于研究人员进行异常检测和分类建模，每个样本都带有精确的时间戳，并附有源 IP、目标 IP、端口号、协议类型等元数据，方便构建基于时序的行为分析模型。

该数据集能够较好反映工业网络中协议复杂、设备异构和攻击类型多样的特点^[1]，适用于机器学习、深度学习和安全检测算法的训练与验证。为保证后续实验具备可比性，本文不改变模型中既有的数据划分顺序，而是在统一预处理工艺下完成所有模型训练与评估。

本文实验以 Edge-IIoTset 二分类任务为基础，将 Normal 视为负类，将 Attack 视为正类。模型输入均来自相同的预处理结果，并严格遵循“先划分、后选择、再标准化”的流程。也就是说，特征筛选和标准化参数只在训练集上拟合，验证集和测试集仅使用训练阶段得到的参数进行转换，从而避免测试信息泄漏。

从实际输出可知，源数据规模为 1945449 条样本、99 个原始字段，其中标签列为 Attack_type。预处理阶段遵循“先划分、后选择、再标准化”的原则：先将数据划分为训练集、验证集和测试集，再仅在训练集上完成特征选择与标准化参数拟合，避免验证集和测试集信息泄漏进入训练流程。最终保留 93 个特征用于建模。训练、验证与测试数据分布如表 2.1 所示。

表 2.1 数据集划分与类别分布

数据子集	正常	攻击	合计
训练集	979737	382077	1361814
验证集	139962	54583	194545
测试集	279925	109165	389090

由表 2.1，正常与攻击两类样本在三个子集中均保持相对稳定的比例关系，测试集共有 389090 条样本，其中正常流量 279925 条，攻击流量 109165 条。该规模能够支撑本文开展多轮压力测试与横向对比实验。

本文二分类任务中，将攻击视为正类，将正常视为负类。根据混淆矩阵，真正例 TP 表示攻击样本被正确识别为攻击，假正例 FP 表示正常样本被误报为攻击，真负例 TN 表示正常样本被正确识别为正常，假负例 FN 表示攻击样本被漏检为正常。各评价指标的计算公式与含义如下。

表 2.2 主要评价指标计算公式与含义

指标	计算公式	含义
准确率	$(TP+TN)/(TP+TN+FP+FN)$	所有样本中被正确分类的比例，反映整体分类正确率。
正常召回率	$TN/(TN+FP)$	正常流量被正确识别为正常的比例，也可表示为 1-误报率。
平衡准确率	$0.5 \times [TP/(TP+FN) + TN/(TN+FP)]$	同时考虑攻击召回与正常召回，适合类别比例不完全均衡的入侵检测任务。
精确率	$TP/(TP+FP)$	被模型判定为攻击的样本中，真实攻击样本所占比例。
正常召回率/攻击召回率	$TP/(TP+FN)$	真实正常样本/攻击样本被模型正确检出的比例。
F1	$2 \times \text{精确率} \times \text{召回率} / (\text{精确率} + \text{召回率})$	精确率与召回率的调和平均值，用于综合衡量检出准确性与检出完整性。
ROC_AUC	$AUC \{FPR=FP/(FP+TN), TPR=TP/(TP+FN)\}$	ROC 曲线下方面积，衡量模型在不同阈值下区分正常与攻击样本的整体排序能力。
误报率	$FP/(FP+TN)$	正常流量被误报为攻击的比例，数值越低说明误报越少。
漏报率	$FN/(FN+TP)$	攻击流量被漏判为正常的比例，数值越低说明漏检越少。
极端场景得分	$0.7 \times \text{正常召回率} + 0.3 \times \text{攻击召回率}$	本文用于极端扰动场景的综合指标，更强调平衡误报和漏报，关注平衡检出能力。

2.2 CNN-LSTM-GRU 相关技术

2.2.1 卷积神经网络

深度特征提取技术的核心目标是从原始输入数据中自动学习具有判别能力的高层特征表示。与传统机器学习方法依赖人工特征工程不同，深度神经网络可以通过多层非线性映射逐步提取数据中的局部模式和高阶特征组合。在物联网入侵检测任务中，网络流量通常由协议字段、连接统计特征、流量行为特征和攻击相关特征组成，攻击行为并不一定只表现为单个字段异常，而可能体现为多个字段之间的组合变化。因此，能够自动学习局部特征交互关系的卷积神经网络适合作为基线模型的前端特征提取模块。

卷积神经网络是一类具有局部连接、权值共享和层次化特征提取能力的深度神经网络。其最初广泛应用于图像识别任务，但由于卷积操作本质上可以在局部窗口内提取相邻元素之间的关系，因此也可以扩展到一维序列、表格特征和网络流量数据建模中。对于物联网入侵检测而言，本文使用一维卷积神经网络对标准化后的流量特征进行局部模式提取，使模型能够捕获若干相邻特征之间的组合关系。

设输入特征序列为：

$$X = [x_1, x_2, \dots, x_T]。 \quad (2.2.1)$$

式中， T 表示输入特征长度。对于一维卷积操作，卷积核在输入序列滑动，并对局部窗口内的特征进行加权求和，其计算过程可表示为：

$$h_t = f\left(\sum_{i=0}^{k-1} w_i x_{t+i} + b\right)。 \quad (2.2.2)$$

式中， k 表示卷积核大小， w_i 表示卷积核参数， b 表示偏置项， $f(\cdot)$ 表示非线性激活函数， h_t 表示第 t 个位置的卷积输出。通过多个卷积核并行计算，网络可以从不同角度提取输入特征中的局部组合模式。

卷积神经网络通常由输入层、卷积层、池化层、激活层和全连接层等组成。对于本文的物联网入侵检测任务，各组成部分的作用如下。

1) 输入层。输入层负责接收经过预处理后的网络流量特征。本文中每个样本

经特征选择和标准化后形成固定长度的一维特征向量。为了适配 Conv1D 结构，需要将特征向量重构为三维张量形式：

$$X_i \in R^{d \times 1}。 \quad (2.2.3)$$

式中， d 表示特征维度。该过程并不改变特征本身含义，而是为一维卷积提供统一输入格式。

2) 卷积层。卷积层是 CNN 的核心结构，用于提取局部特征组合关系。在网络流量数据中，某些攻击行为可能同时体现在连接持续时间、数据包统计、协议字段和端口行为等多个特征上。卷积层通过局部感受野扫描输入特征，可以捕获这些局部相关字段之间的联合变化模式。相比直接使用全连接层，卷积层通过权值共享减少了参数数量，有助于提升模型训练效率和泛化能力。

3) 池化层。池化层通常接在卷积层之后，用于对卷积输出进行下采样。本文基线模型采用最大池化操作，其基本形式为：

$$p_j = \max_{t \in \Omega_j}(t) * h_t。 \quad (2.2.4)$$

式中， Ω_j 表示第 j 个池化窗口。最大池化能够保留局部区域内最显著的响应值，从而突出攻击相关强特征，同时减少特征维度和计算量。对于网络流量检测任务，池化层还可以在在一定程度上抑制局部噪声，使模型更关注关键判别模式。

4) 激活层。激活函数用于为神经网络引入非线性表达能力。若缺少激活函数，多层神经网络本质上仍只能表示线性变换，难以处理复杂攻击模式。本文在中间层中主要采用修正线性单元（Rectified Linear Unit, ReLU）激活函数，其表达式为：

$$ReLU(x) = \max(0, x)。 \quad (2.2.5)$$

$ReLU$ 能够缓解梯度消失问题，提高模型训练速度，并增强网络对非线性流量特征的拟合能力。

5) 全连接层。全连接层通常位于网络后端，用于将前面卷积层和循环层提取到的高层特征映射到最终分类空间。对于二分类入侵检测任务，全连接层将综合表示转换为攻击概率，并通过阈值判断样本属于 Normal 还是 Attack。

2.2.2 长短期记忆网络

物联网入侵检测中的网络流量不仅具有字段之间的空间组合关系，还具有一定的序列依赖特征。某些攻击行为往往不是由单个特征独立决定，而是由多个流量行为连续变化共同构成。长短期记忆网络是在 RNN 基础上发展而来的改进结构^[17]。LSTM 通过引入输入门、遗忘门、输出门和细胞状态，使网络能够选择性地保留或遗忘历史信息，从而缓解传统 RNN 在长序列建模中的梯度消失问题。其主要计算过程如下：

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i), \quad (2.2.6)$$

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f), \quad (2.2.7)$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o), \quad (2.2.8)$$

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c), \quad (2.2.9)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad (2.2.10)$$

$$h_t = o_t \odot \tanh(c_t). \quad (2.2.11)$$

式中， i_t 为输入门，用于控制当前输入写入细胞状态的比例； f_t 为遗忘门，用于控制历史信息保留比例； o_t 为输出门，用于控制细胞状态向隐藏状态输出的比例； c_t 为细胞状态， h_t 为隐藏状态， $\odot$ 表示逐元素乘法。在物联网入侵检测任务中，LSTM 可以通过细胞状态保留前序特征中的关键信息，使模型不仅依据局部字段异常进行判断，还能综合考虑较长特征序列中的上下文模式。

2.2.3 门控循环单元

门控循环单元是另一种常用的门控循环神经网络结构^[18]。与 LSTM 相比，GRU 结构更加简洁，它将 LSTM 中的输入门和遗忘门合并为更新门，并通过重置门控制历史状态对候选状态的影响。其计算过程为：

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z), \quad (2.2.12)$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r), \quad (2.2.13)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h), \quad (2.2.14)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t. \quad (2.2.15)$$

式中, z_t 表示更新门, 用于控制历史状态和候选状态的融合比例; r_t 表示重置门, 用于控制上一时刻隐藏状态对当前候选状态的影响; $\tilde{h}_t$ 表示候选隐藏状态; h_t 表示当前隐藏状态。GRU 的参数量通常少于 LSTM, 训练速度较快, 更适合计算资源受限的应用场景。

2.2.4 CNN-LSTM-GRU 混合模型技术

单一神经网络结构通常只能突出某一方面能力。CNN 善于提取局部特征组合, 但对长距离依赖关系建模能力有限; LSTM 能够捕获长期依赖, 但计算开销相对较大; GRU 结构轻量, 能够较快完成状态更新, 但单独使用时对复杂局部特征的提取能力不如卷积结构。因此, 将 CNN、LSTM 和 GRU 结合, 可以充分利用三类结构的互补优势。

在 Kilichev 等提出的 IoT EVCS 入侵检测模型中, CNN-LSTM-GRU 被用于分析物联网电动汽车充电站场景下的网络流量。该模型首先使用一维卷积 (One-Dimensional Convolution, Conv1D) 和一维最大池化 (One-Dimensional Max Pooling, MaxPooling1D) 进行空间特征提取, 然后使用 LSTM 和 GRU 处理序列特征, 最后通过展平层 (Flatten)、全连接层、随机失活层 (Dropout) 和分类层完成攻击类型识别^[7]。

其中, 前端 CNN 模块负责提取网络流量特征中的局部空间依赖关系; 中部 LSTM-GRU 模块负责建模特征序列中的长期和短期依赖关系; 后端全连接层负责融合高层表示并输出分类结果。对于本文的二分类物联网入侵检测任务, CNN-LSTM-GRU 的作用可以进一步解释为以下三点。

第一, CNN 层用于提取局部字段组合关系。网络流量中的攻击特征往往不是孤立存在的, 而是体现在多个字段之间的联合变化中。一维卷积能够在较低参数规模下捕获局部特征模式, 为后续序列建模提供更稳定的输入表示。

第二, LSTM 层用于保留较长范围的上下文信息。当攻击行为包含多个连续或相关特征片段时, LSTM 可以通过门控机制保留前序信息, 使模型更好地理解复杂流量模式。

第三, GRU 层用于进一步压缩序列状态并提高建模效率。GRU 通过更新门

和重置门完成状态选择，在降低参数量的同时保留关键时序信息，有助于提升模型在物联网场景中的实际部署可行性。

在分类阶段，本文针对 Normal/Attack 二分类任务使用 Sigmoid 输出攻击概率：

$$\hat{y} = \sigma(W_d * u + b_d)。$$
 (2.2.16)

式中， $\hat{y}$ 表示模型预测为 Attack 的概率。当 $\hat{y} \geq 0.5$ 时，样本被判定为攻击流量；当 $\hat{y} < 0.5$ 时，样本被判定为正常流量。训练阶段采用二分类交叉熵作为损失函数：

$$L_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]。$$
 (2.2.17)

式中， N 表示样本数量， y_i 表示真实标签， $\hat{y}_i$ 表示预测概率。此外，模型中引入 Dropout 层用于随机屏蔽部分神经元输出，以降低模型对少数强响应特征的过拟合风险。Dropout 的基本形式可表示为：

$$\tilde{u} = \frac{m \odot u}{1 - p}。$$
 (2.2.18)

式中， m 为服从伯努利分布的随机掩码， p 为丢弃率， u 为原始特征表示。通过 Dropout 正则化，模型能够在训练阶段学习更稳健的特征组合。综上，CNN-LSTM-GRU 混合模型能够同时利用 CNN 的局部特征提取能力、LSTM 的长期依赖建模能力和 GRU 的轻量化状态更新能力，因此适合作为本文开展鲁棒性压力测试和后续优化的基线模型。

2.3 鲁棒表示学习技术

本文除构建 CNN-LSTM-GRU 基线模型外，还进一步引入鲁棒表示学习技术，以提升模型在复杂输入退化条件下的稳定性。

2.3.1 去噪自编码器

自编码器（Auto-Encoder, AE）是一类典型的无监督表示学习模型，其基本思想是通过编码器将输入数据压缩到低维潜在空间，再通过解码器重建原始输入^[8]。设输入为 x ，编码器和解码器分别表示为 $E(\cdot)$ 和 $D(\cdot)$ 。

训练目标通常是最小化输入与重建结果之间的差异：

$$L_{rec} = \|x - \hat{x}\|_2^2. \quad (2.3.1)$$

式中， $\|\cdot\|_2$ 表示向量的二范数，即欧氏距离，用于度量样本表示与类别原型之间的差异，距离越小，说明样本表示越接近对应类别原型，表示如下：

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + x_3^2 + \dots + x_n^2}. \quad (2.3.2)$$

去噪自编码器（Denoising Auto-Encoder, DAE）在普通自编码器基础上引入受污染输入。其训练过程不是直接重建输入 x ，而是先对输入进行噪声扰动得到 $\tilde{x}$ ，再要求模型从 $\tilde{x}$ 中恢复出相对稳定的表示：

$$\hat{x} = D(E(\tilde{x})). \quad (2.3.3)$$

该机制能够促使模型学习输入特征之间的潜在相关性，减少噪声对特征表示的影响。对于物联网入侵检测任务，DAE 可用于缓解传感噪声、通信抖动和协议解析误差造成的输入偏移，使分类器获得更加稳定的中间表示。

2.3.2 数据增强

数据增强是一类通过构造扰动样本提升模型泛化能力的方法。在网络流量任务中，增强方式可以根据部署风险设计为噪声注入和特征丢弃。本文中的噪声增强可表示为：

$$\tilde{x} = x + \varepsilon, \varepsilon \sim \mathcal{N}(0, \sigma^2). \quad (2.3.4)$$

式中， ε 为高斯噪声， σ 为噪声标准差。特征缺失增强则可表示为：

$$\tilde{x} = m \odot x. \quad (2.3.5)$$

式中， $m \in \{0, 1\}^d$ ， m 为随机缺失掩码。当 $m_j = 0$ 时，表示第 j 个特征被屏蔽；当 $m_j = 1$ 时，表示该特征保持观测状态。通过在训练阶段主动构造噪声样本和缺失样本，模型能够提前接触真实部署中可能出现的输入退化形式，从而学习更平滑的判别边界。

2.3.3 一致性约束

一致性约束是一类常见的鲁棒学习思想，其核心假设是：同一样本在干净输

入和受扰输入下应具有相近的预测结果或中间表示^[7]。设干净输入为 x ，受扰输入为 $\tilde{x}$ ，模型输出分别为 $f(x)$ 和 $f(\tilde{x})$ ，则一致性损失可表示为：

$$L_{cons} = \|f(x) - f(\tilde{x})\|_2^2。 \quad (2.3.6)$$

在物联网入侵检测中，一致性约束可以减少输入噪声或特征缺失导致的表示漂移，使模型在非理想输入条件下仍能保持稳定预测。

2.3.4 可靠性门控机制

门控机制是一种通过学习权重对不同特征或表示维度进行选择保留的方法。在输入存在噪声或缺失时，并非所有维度都具有同等可信度。可靠性门控的目标是根据样本状态自动判断哪些维度更加可靠，并在分类前对不可信维度进行抑制。设编码器输出表示为 h ，可靠性门控向量为 r ，则门控后的表示可写为：

$$h^* = r \odot h。 \quad (2.3.7)$$

式中， $r_i \in [0,1]$ 表示第 i 个表示维度的可信程度。当 r_i 接近 1 时，说明该维度信息较可靠；当 r_i 接近 0 时，说明该维度可能受到噪声或缺失影响，应降低其对分类结果的贡献。在本文中，MR²G 和 PGRG 则进一步将门控机制压缩到单模块结构中，使模型能够在表示空间中动态调节特征可靠性。

2.3.5 原型学习

原型学习是一类基于类别中心或代表性样本进行判别的表示学习方法。其基本思想是：同一类别样本在表示空间中应更接近本类原型，而远离其他类别原型^[10]。设 Normal 类原型为 c_N ，Attack 类原型为 c_A ，样本表示为 h ，则其到两类原型的距离可表示为：

$$d_N = \|h - c_N\|_2， \quad (2.3.8)$$

$$d_A = \|h - c_A\|_2。 \quad (2.3.9)$$

在物联网入侵检测任务中，输入退化和真实攻击异常可能都会造成样本表示偏移。仅依赖输入扰动程度进行判断，可能难以区分“正常样本受到噪声污染”和“攻击样本本身具有异常模式”两种情况。引入 Normal/Attack 类别原型后，模型可以根据样本更接近正常原型还是攻击原型进行判别，从而为可靠性门控提供类

别参照。本文提出的模块正是基于这一思想，将缺失掩码、原型偏离距离和可靠性门控结合起来，在不直接恢复不可观测原始特征值的前提下，对表示空间进行调节，以增强模型对输入退化和真实攻击异常的区分能力。

2.3.6 四鲁棒模块技术原理

上述鲁棒表示学习技术在本文中并不是孤立使用，而是被组织为第四章的四个双鲁棒联合模块。四模块的共同目标是：在不改变 CNN-LSTM-GRU 主干判别能力的前提下，从输入修复、训练增强、特征重权和输出对齐四条路径提升模型对噪声扰动、特征缺失及联合退化的适应能力。

缺失掩码编码-去噪自编码器（Missing Mask Encoding-Denoising Auto-Encoder, MME_DAE）模块对应“缺失感知和去噪重建”思路。该模块将受扰特征与缺失掩码共同输入模型，使网络能够区分真实零值和不可观测字段；随后通过去噪自编码器重建相对稳定的中间表示，再送入分类主干。该路径适合处理部分字段缺失或受污染但仍可由上下文关系推断的输入退化场景。

特征缺失增强-噪声增强训练（Feature Dropout Augmentation-Noise Training Augmentation, FDA_NTA）模块对应“特征缺失增强和噪声增强训练”思路。该模块不额外增加复杂结构，而是在训练阶段动态构造不同强度的随机特征缺失和高斯噪声样本，使分类器提前接触部署环境中可能出现的异常输入形式，从而学习更加平滑的判别边界，提高模型对未知扰动强度的泛化能力。

自适应特征重权-自适应噪声重权（Adaptive Feature Reweighting-Adaptive Noise Reweighting, AFR_ANR）模块对应“缺失门控和噪声门控”的可靠性重权思路。该模块分别根据缺失掩码和特征扰动状态估计不同维度的可信程度，并对输入特征或中间表示进行逐维加权。其核心不是恢复原始数值，而是抑制低可信维度、保留稳定且有判别力的特征，从而降低噪声和缺失对分类结果的干扰。

双一致性鲁棒约束（Dual Consistency Robust Constraint, DCRC）模块对应“一致性约束”的表示稳定化思路。该模块使用共享编码器分别处理干净样本和联合受扰样本，并约束二者的预测结果或中间表示保持接近。通过这种方式，模型不仅需要在受扰输入下完成正确分类，还需要减少由噪声和缺失引起的表示漂移，从而降低判别翻转的风险。

进一步地，四个模块在误差模式上具有互补性，因此本文采用软投票方式融合其预测概率。与单一模块相比，软投票能够综合不同鲁棒路径的判断结果：当某一模块在高噪声场景表现更好、另一模块在高缺失场景表现更强时，概率融合可以降低单一模型局部失效带来的风险。因此，四模块模型在本文中主要承担鲁棒机制有效性验证与综合性能提升的作用，也为后面进一步凝练 MR²G 和 PGRG 单模块结构提供技术依据。

2.4 本章小结

本节围绕本文后续模型设计所需的理论基础，对深度特征提取技术、时序依赖建模技术和鲁棒表示学习技术进行了介绍。

首先，CNN 通过卷积、池化、激活和全连接等结构提取网络流量中的局部组合特征；其次，LSTM 和 GRU 通过门控循环结构建模特征序列中的长期和短期依赖关系；再次，CNN-LSTM-GRU 混合模型能够综合利用三类结构的优势，适合作为物联网入侵检测基线模型；最后，去噪自编码器、数据增强、一致性约束、可靠性门控和原型学习为后续鲁棒优化模块提供了理论支撑。基于上述技术，本文将在后续章节中构建统一基线模型，并进一步开展噪声扰动、特征缺失和联合扰动条件下的鲁棒性分析与优化。

3 基于 CNN-LSTM-GRU 的四模块优化软投票模型

3.1 引言

本章围绕 CNN-LSTM-GRU 基线模型的检测能力与鲁棒性性能退化点展开分析。前文已经说明，物联网与工业物联网场景中的网络流量容易受到传感噪声、通信抖动、协议解析误差以及字段缺失等因素影响，因此仅在干净测试集上报告分类准确率，难以全面反映模型在真实部署环境中的稳定性。本章首先在普通环境下测试基线模型，确认其在标准输入条件下具备较强的二分类检测能力；随后进一步构造类别比例变化、噪声扰动和特征缺失等压力测试场景，观察模型在非理想输入条件下的性能变化。

通过将普通环境结果与压力测试结果进行对照，可以更加清晰地识别模型的主要失效模式。若模型在普通环境中准确率很高，但在噪声或缺失条件下出现误报率升高、攻击召回率下降等现象，则说明模型对输入质量存在明显依赖。这类问题在实际 IoT/IIoT 安全监测中具有较高风险：误报过多会造成告警泛滥并增加运维负担，漏报过多则可能导致攻击流量被放行。

因此，本章并不将基线模型的高精度视为研究终点，而是将其作为后续鲁棒优化的参照对象。通过普通测试、类别漂移测试、噪声扰动测试和特征缺失测试，本章逐步分析基线模型在不同输入退化条件下的稳定性边界，并据此提出后续优化方向，为后文构建缺失感知、降噪增强、门控重权和一致性约束等鲁棒模块奠定实验基础。

3.2 基线模型压力测试和性能退化测试

3.2.1 普通环境下的基线检测性能

在正式进行鲁棒性分析之前，本文首先对 CNN-LSTM-GRU 基线模型进行普通环境测试。实验结果表明，该模型在干净测试集上表现极为优异。混淆矩阵显示，测试集中仅有 3 条正常流量被误判为攻击流量，没有攻击样本被漏检。

这一结果说明，若仅从普通环境的平衡准确率出发，基线模型似乎已经接近“最优”。但高精度并不等于高鲁棒性，尤其在边缘采集、异构网关和多源日志融合场景下，模型面对输入退化时是否还能保持稳定识别能力，才是真正决定工程

可用性的关键。

3.2.2 基线模型在类别漂移下的性能表现

除普通环境整体测试外，本文进一步在不引入噪声和特征缺失的前提下，对基线模型进行了类别比例失衡补充测试。按照攻击:正常=1:1、1:3、1:9、3:1、9:1五种比例，从验证集与测试集中分别构造精确比例子集，并在验证集上搜索最优分类阈值，以检验模型在攻击占比显著变化时的稳定性。该实验关注点在于：即使输入数据质量未受破坏，测试集先验分布变化是否仍会影响模型的判别稳定性。

表 3.1 显示，在五种攻击:正常比例下，基线模型均保持接近满分的准确率、平衡准确率与极端场景得分。其中在 1:3 和 1:9 两种正常流量占优场景中，验证集最优阈值由 0.01 调整为 0.97 后，模型仍可实现 99.9997%的准确率和 99.9998%的平衡准确率；在 3:1 和 9:1 两种攻击流量占优场景中，各项指标达到 1.000000。说明相较于类别比例变化，当前基线模型对输入噪声和特征缺失更为敏感，后续鲁棒优化的重点应放在数据质量退化而非类别先验漂移上。

表 3.1 基线模型在不同类别比例下的测试结果

比例	阈值	准确率	平衡准确率	正常召回率	攻击召回率	误报率	极端场景得分
1:1	0.01	999991%	99.9991%	99.9982%	100%	0.0018%	99.9987%
1:3	0.97	999997%	99.9998%	99.9996%	100%	0.0004%	99.9997%
1:9	0.97	999997%	99.9998%	99.9996%	100%	0.0004%	99.9997%
3:1	0.01	100%	100%	100%	100%	0%	100%
9:1	0.01	100%	100%	100%	100%	0%	100%

3.2.3 基线模型在噪声扰动下的性能退化

表 3.2 与图 3.1 给出了基线模型在不同噪声标准差下的表现。可以看到，当噪声标准差处于 0.05 至 0.2 区间时，模型仍能维持接近满分的性能；但当噪声标准差增至 0.3 时，准确率下降至 99.574%，精确率下降至 98.505%，说明噪声开始破坏判别边界的稳定性，但是扰动几乎可以忽略不计。进一步地，在 0.5 和 0.7 两个高噪声场景下，模型分别下降至 89.545%和 72.101%的准确率，平衡准确率分别降为 92.729%和 80.527%。

值得注意的是，在强噪声环境中，攻击召回率仍保持接近 1 的高水平，而精

确率与正常召回率明显下降,这意味着模型更倾向于将本来正常的流量误判为攻击流量,误报率显著上升。对于真实网络运行而言,这种“宁可多报也不漏报”的倾向虽然保住了攻击召回,但会造成告警泛滥、系统负载增加以及运维信任度下降。

表 3.2 基线模型在不同噪声强度下的测试结果

噪声标准差	准确率	平衡准确率	精确率	攻击召回率	极端场景得分
0.05	99.999%	99.999%	99.997%	100%	99.999%
0.1	99.999%	99.999%	99.997%	100%	99.999%
0.2	99.998%	99.998%	99.994%	100%	99.998%
0.3	99.574%	99.704%	98.505%	100%	99.586%
0.5	89.545%	92.729%	72.857%	99.985%	89.827%
0.7	72.101%	80.527%	50.141%	99.727%	72.847%




图 3.1 基线模型噪声扰动性能变化曲线


3.2.4 基线模型在特征缺失下的性能退化

相比噪声扰动,特征缺失对基线模型造成的影响更具累积性。由表 3.3 与图 3.2 可知,当缺失率为 0.1 时,模型性能仅有轻微下降;缺失率提高到 0.3 时,准确率下降至 98.885%,攻击召回率下降至 96.132%;当缺失率继续增加到 0.5 与 0.7 时,模型出现更明显的退化,其中攻击召回率分别降至 83.921%与 60.372%,漏报率分别上升至 16.079%与 39.628%。

这说明特征缺失直接削弱了模型对攻击模式的识别能力。与噪声场景下的误报增多不同,缺失场景下的主要问题是漏检增加,即部分攻击行为由于关键字段被遮蔽而无法被准确识别。对于工业物联网安全监测系统而言,漏检往往意味着攻击流量被放行,因此其风险更高,也更需要通过结构优化来弥补。

表 3.3 基线模型在不同特征缺失率下的测试结果

缺失率	准确率	平衡准确率	攻击召回率	缺失预测值	极端场景得分
0.1	99.953%	99.917%	99.836%	0.164%	99.949%
0.3	98.885%	98.045%	96.132%	3.869%	98.811%
0.5	95.346%	91.861%	83.921%	16.079%	95.038%
0.7	88.598%	79.989%	60.372%	39.628%	87.835%

**图 3.2** 基线模型特征缺失性能变化曲线

3.2.5 性能退化原因分析

综合图表结果可以看出，基线模型在普通环境下的高精度掩盖了其在复杂部署条件下的明显性能退化。噪声扰动主要导致正常流量召回下降和误报率上升，而特征缺失主要导致攻击召回下降和漏检率上升。两类问题的作用路径不同，决定了单一的优化方法难以同时兼顾两种扰动。

因此，后续优化不应局限于单一的优化方向，而应从缺失感知、显式重建、增强训练、门控重权与一致性约束等多种角度展开，并最终构建能够适应联合扰动场景的集成模型。这也是本文在第四章中引入四类鲁棒模块并进行软投票集成的直接动机。

3.3 四模块软投票模型

之前的测试实验表明，基线模型在噪声与特征缺失下的失效方式并不相同。若仅针对一种扰动开展优化，往往会在另一种扰动下失去效果，甚至出现负迁移。因此，本文采用分层推进的设计思路：先分别构建缺失鲁棒模块与降噪鲁棒模块，分析各自作用机理与局限，再进一步形成双鲁棒联合模块，最终通过四模块软投

票集成实现综合增强。

这一设计策略并非将多个模块简单串联，而是将不同类型的鲁棒思想显式组织起来。部分模块强调对缺失掩码信息的利用，部分模块强调输入重建与噪声抑制，部分模块强调通过数据增强提升泛化能力，还有部分模块通过一致性约束缩小干净样本与受扰样本的表征差异。这样的差异化组合使最终模型能够更稳定地覆盖多种退化模式。

3.3.1 抗特征缺失模块

缺失鲁棒部分包括 MME、FDA、AFR 与 CRC 四类模块。MME 模块将原始特征与缺失掩码拼接后送入共享 CNN-LSTM-GRU 主干，从而显式利用“哪些字段缺失”这一信息；FDA 模块在训练阶段对样本随机执行特征丢弃增强，使模型习惯于在不完整输入下学习稳定判别边界；AFR 模块通过门控网络自适应重加权特征，使观测充分且更具判别力的字段获得更高权重；CRC 模块则通过干净样本与缺失样本之间的一致性约束，促使编码器学习更稳健的公共表示。

表 3.4 高缺失场景下各模块相对基线的增益

模块	平衡准确率变化 量	攻击召回率变化 量	极端场景得分变 化量
AFR	17.686%	36.515%	10.155%
CRC	17.886%	37.625%	9.990%
FDA	18.823%	37.676%	11.281%
MME	14.274%	32.250%	7.084%

从缺失率对比结果来看，四类模块均能在不同程度上缓解特征缺失造成的性能退化。尤其在高缺失率 0.7 的极端场景下，四个模块都明显优于基线，其中 FDA 的改进最为突出，其平衡准确率变化量达到 18.823%，攻击召回率变化量达到 37.676%；CRC 与 AFR 紧随其后，说明增强训练与一致性约束对高缺失环境具有较强适应性。表 3.4 列出了缺失率为 0.7 时各模块相对基线的主要增益。

3.3.2 抗噪声干扰模块

针对噪声扰动，本文构建了 DAE、NTA、ANR 与 NCC 四类模块。DAE 通过显式重建分支先对受污染输入进行恢复，再将重建结果送入分类主干；NTA 通过随机高斯噪声增强训练，促使模型在训练阶段提前暴露于不同噪声水平；ANR 利用特征值及其绝对值构建门控重权网络，自适应压制受噪声影响较大的维度；

NCC 则通过干净样本与噪声样本的一致性约束，增强表示空间的平滑性。

表 3.5 降噪鲁棒模块相对基线的增益

模块	平均准确率变化量	平均平衡准确率变化量	平均极端场景得分变化量
ANR	6.038%	3.892%	5.848%
DAE	6.428%	4.465%	6.254%
NCC	5.402%	2.737%	5.166%
NTA	5.774%	3.381%	5.562%

平均增益结果表明，DAE 在四个降噪模块中综合效果最好，其平均准确率变化量为 6.428%，平均平衡准确率变化量为 4.465%，平均极端场景得分变化量为 6.254%；ANR 与 NTA 紧随其后；NCC 同样能够带来正向收益，但幅度相对温和。由此可见，显式重建与噪声增强训练在当前任务上对提升抗噪声能力更为直接。


3.3.3 噪声与缺失联合增强策略

在单项优化分析基础上，本文进一步构建四个双鲁棒联合模块。MME_DAE 结合掩码编码和显式降噪重建，先对缺失信息进行感知，再通过重建分支恢复有效表达；FDA_NTA 将特征缺失增强与噪声增强联合纳入训练序列，使模型在训练阶段同时接触两类退化形式；AFR_ANR 将缺失门控与噪声门控相乘，形成双门控重权机制，对不同扰动来源进行联合抑制；DCRC 则在干净样本与联合受扰样本之间施加一致性约束，以获得更稳健的共享嵌入表示。从具体实现看，四个联合模块并不是简单将单模块并排叠加，而是分别围绕“信息补回、联合暴露、动态抑制和表示对齐”四条路径展开，因此它们在联合扰动条件下具有明显的功能分工与互补关系。

联合扰动平均结果说明，AFR_ANR 与 FDA_NTA 的综合提升最为显著。AFR_ANR 的平均平衡准确率变化量为 10.378%，平均攻击召回率变化量为 18.201%；FDA_NTA 的平均准确率变化量为 7.076%，平均极端场景得分变化量为 7.343%；DCRC 虽然绝对增益略低，但在多种联合扰动场景下保持了较稳定的改善效果。表 3.6 列出了双鲁棒联合模块相对基线的主要增益。图 3.3 给出了双鲁棒模块平均平衡准确率增益比较。

表 3.6 双鲁棒联合模块相对基线的平均改变量

模块	平均准确率变化量	平均平衡准确率变化量	平均攻击召回率变化量	平均极端场景得分变化量
AFR_ANR	6.945%	10.378%	18.201%	7.249%
DCRC	4.368%	7.604%	14.978%	4.654%
FDA_NTA	7.076%	10.084%	16.938%	7.343%
MME_DAE	5.067%	6.069%	8.354%	5.156%

**图 3.3 双鲁棒联合模块平均平衡准确率改变量比较**

3.3.4 四模块软投票集成策略

考虑到四个双鲁棒模块在不同扰动区域的表现各有侧重，本文没有简单选择单一最优模块，而是构建了四模块软投票集成模型。对于测试样本 x ，分别由 MME_DAE、FDA_NTA、AFR_ANR 和 DCRC 输出攻击概率 $p1(x)$ 、 $p2(x)$ 、 $p3(x)$ 与 $p4(x)$ ，最终集成概率定义为各成员输出得分的加权平均，如式 (3.3.1) 所示：

$$p_{ensemble(x)} = \frac{p1(x) + 1.4 * p2(x) + 1.4 * p3(x) + p4(x)}{4}。 \quad (3.3.1)$$

软投票策略的优势在于能够综合不同模块的偏好：当某一模块在高缺失场景更强时，其他模块可在高噪声或联合扰动场景下提供补偿，从而降低单模块在局部区域表现突出的偶然性。基于实验的结果可知，该四模块集成模型在后续横向比较中表现出最强的特征缺失适应能力和更均衡的综合鲁棒性，因此本文将作为最终优化模型。

3.4 实验结果及分析

3.4.1 实验设置

为保证实验结论具有可比性,本文在本节中统一说明数据来源、预处理流程、训练设置、扰动构造和评价原则。按照实验可复现性要求,本文将所有模型置于相同的数据划分、特征维度、标准化参数和测试阈值条件下进行评估,避免由于数据处理差异造成不公平比较。

表 3.7 实验参数设置

训练参数	参数值
数据划分	训练集 70%、验证集 10%、测试集 20%，随机种子 42
特征选择	Select K Best，保留TOP _K =93个特征
标准化策略	仅在训练集拟合 Standard Scaler，再作用于验证集和测试集
基线模型	CNN-LSTM-GRU: Conv1D(32,3)-MaxPool-Conv1D(64,3)-MaxPool-LSTM(64)-GRU(64)-Dense(128)-Dropout(0.5)-Sigmoid
训练轮数	基线：20；鲁棒模块：12
批处理大小	32
优化器	Adam
分类阈值	0.50
噪声扰动设置	标准化特征空间加入高斯噪声，标准差为 0.05、0.1、0.2、0.3、0.5、0.7，扰动特征比例为 1.0
特征缺失设置	随机特征缺失率为 0.1、0.3、0.5、0.7，缺失值填充为 0.0
联合扰动训练设置	缺失率动态采样 0.1-0.5，噪声标准差动态采样 0.05-0.35
回调策略	EarlyStopping(monitor=val_auc, patience=3)、ReduceLROnPlateau(factor=0.5, patience=2, min_lr=1e-7)、ModelCheckpoint

如表 3.7 所示,本章实验参数主要包括基线模型训练参数、鲁棒模块训练参数以及噪声/缺失压力测试参数。基线模型用于形成统一参照,缺失鲁棒模块、降噪鲁棒模块和双鲁棒联合模块均在相同数据协议下训练,最终通过四模块软投票输出攻击概率。

表 3.8 实验硬件信息

实验环境	
深度学习框架	TensorFlow/Keras 2.20.0
操作系统	Windows11 本地 Anaconda 环境
Python 版本	3.12.13
CUDA 版本	13.1
内存	32GB
GPU	Nvidia RTX 4070 GPU 12GB
CPU	Intel(R) Core(TM) i7-12700KF (3.60 GHz)

如表 3.8 所示，本章实验在统一的 Python 深度学习环境下完成。实验代码框架使用 TensorFlow/Keras 实现，所有模型均在相同的数据划分、特征选择结果、标准化参数和评价脚本下训练与测试。

3.4.2 消融实验

由于联合模块模型得到的是 4 个独立训练的双鲁棒模块，而非单个内部硬串的大模型，本论文补充构造了几个软投票版本：AFR_ANR 与 DCRC 的二模块版、MME_DAE 与 AFR_ANR 与 DCRC 三模块版，以及 MME_DAE 与 FDA_NTA 与 AFR_ANR 与 DCRC 的四模块版，并联合扰动协议下进行比较综合性能。因此，取不同参数环境扰动下结果的平均值进行比较，比较它们的平均性能。

表 3.9 二、三、四模块在联合扰动场景下的平均性能比较

模型	模块数	平衡准确率	攻击召回率	误报率	极端场景得分
2M 版	2	98.259%	99.336%	2.817%	97.829%
3M 版	3	99.230%	99.268%	0.809%	99.215%
4M 版	4	99.345%	99.027%	0.338%	99.472%

由表 3.9 可知，三模块版相较二模块版已表现出明显增益，其平均平衡准确率由 98.259% 提升至 99.230%，极端场景得分由 97.829% 提升至 99.215%，误报率由 2.817% 降至 0.809%，说明在保留较低集成复杂度的同时，引入 MME_DAE 后模型对联合扰动的适应能力显著增强。进一步地，四模块版在平均平衡准确率、误报率与极端场景得分上继续取得最优，其中平衡准确率达到 99.345%，误报率进一步降至 0.338%；但三模块版的攻击召回率为 99.268%，略高于四模块版的 99.027%，表明三模块方案可作为性能与复杂度折中的备选结构。

结果表明，二模块版保留了门控重权与一致性约束两条关键增强路径，具有结构简洁、推理链路短的特点；三模块引入显式缺失感知的注意力增强模块，进一步增强了判别能力，但是还是略显不足；四模块版更进一步引入显式缺失重建和联合增强训练后，在平衡准确率、攻击召回率与极端场景得分等综合指标上更占优。综合来看，二模块版更适合作为资源受限场景下的轻量替代方案，而四模块版更强调通过模块互补来稳定最终判别边界。考虑到真实 IoT/IIoT 部署中常同时存在字段缺失、噪声漂移与分布偏移等复合问题，本文仍选择四模块软投票模型用于后续横向比较。

3.4.3 基于 TensorFlow 的对照模型对比实验

为了验证四模块软投票模型的综合优势，本文在既有统一框架下引入 4 个近年具有代表性的 TensorFlow/Keras 对照模型，包括 ABCNN-IDS、ITCT/Tab Transformer 适配模型、Lightweight Edge-DNN 与 CST-AFNet。需要说明的是，由于不同论文的原始任务、数据集类型和预处理方式并不完全一致，本文采用的是在统一数据划分、统一特征维数、统一训练轮数和统一阈值条件下的 TensorFlow/Keras 复现版或轻量适配版。比较目标不是逐字逐层复刻原论文，而是在相同实验协议下考察“谁在噪声和特征缺失下更稳”。

这一做法与本文研究目标高度一致。因为本研究关注的是鲁棒性排序，而非单篇论文在其原始设定中的最优成绩。只要所有对照模型都在相同的数据和扰动接口下进行训练与测试，横向比较就能够有效揭示不同结构在复杂输入条件下的适应能力差异。各对照模型的定位如表 3.11 所示。

表 3.10 横向对比模型说明

对照模型	来源年份	说明
ABCNN-IDS	2024	卷积增强型 IoT 入侵检测模型
ITCT/Tab Transformer	2024	Transformer/表格特征交互建模适配版
Lightweight Edge-DNN	2025	轻量化边缘可部署模型
CST-AFNet	2025	双注意力 IoT 入侵检测框架
本文模型	-	四模块软投票集成优化模型

1) 噪声场景的平均性能比较

表 3.11 给出了各模型在多组噪声标准差上的平均表现。可以看到，本文模型的平衡准确率为 99.845%，平均平衡准确率为 99.892%，平均误报率为 0.215%，平均极端场景得分为 99.849%。与 ABCNN-IDS、CST-AFNet 和 ITCT/Tab Transformer 相比，本文模型在各核心指标上均有明显优势，特别是在平衡准确率和极端场景得分上具有稳定提升。

从纯噪声场景的平均结果来看，Lightweight Edge-DNN 的平均平衡准确率略高于本文模型，差值约为 0.107%。这说明轻量化边缘模型在纯噪声条件下具有较强的稳定性。但需要强调的是，这一优势主要体现在纯噪声环境，而非后续将要讨论的特征缺失与联合扰动环境。换言之，本文模型虽然不是所有噪声平均指标上的唯一最优值，但已经处于第一梯队，并明显优于多数近期对照模型。

表 3.11 各模型在噪声场景下的平均性能比较

模型	准确率	平衡准确率	误报率	极端场景得分
ABCNN-IDS(2024)	88.393%	91.843%	16.017%	88.699%
CST-AFNet(2025)	89.121%	92.378%	15.043%	89.409%
ITCT/TabTransformer(2024)	78.132%	84.698%	30.263%	78.714%
Lightweight Edge-DNN(2025)	99.999%	99.999%	0.002%	99.999%
本文模型	99.845%	99.892%	0.215%	99.849%

2) 特征缺失场景的平均性能比较

与噪声场景相比，特征缺失场景更能体现本文方法的核心优势。由表 3.12 可知，本文模型在缺失场景下的平衡准确率为 99.807%，平均平衡准确率为 99.697%，平均攻击召回率为 99.445%，平均极端场景得分为 99.798%。上述指标均优于 4 个对照模型，其中相较性能第二的 Lightweight Edge-DNN，本文模型的平均平衡准确率仍高出 3.236%，平均攻击召回率高出 6.496%。

表 3.12 各模型在特征缺失场景下的平均性能比较

模型	准确率	平衡准确率	攻击召回率	极端场景得分
ABCNN-IDS(2024)	92.395%	86.448%	72.897%	91.868%
CST-AFNet(2025)	88.720%	80.271%	61.020%	87.972%
ITCT/TabTransformer (2024)	94.982%	92.7425	87.638%	94.784%
Lightweight Edge-DNN(2025)	98.002%	96461%	92.949%	97.866%
本文模型	99.807%	99.697%	99.445%	99.798%

这说明本文所采用的掩码感知、显式重建、增强训练与一致性约束组合，对于特征不完整场景具有更强的恢复能力和判别保持能力。尤其在工业网络安全应用中，特征缺失往往来自采集链路异常、字段解析失败或多源日志融合不完全，这类问题在真实部署中并不罕见。因此，本文模型在缺失场景中的显著领先，具有更直接的工程价值。

3) 综合联合鲁棒性比较

图 3.4 汇总了各模型在噪声场景和缺失场景下的平均平衡准确率。可以看到，Lightweight Edge-DNN 在纯噪声场景稍占优势，但在缺失场景明显被本文模型超越；ABCNN-IDS 与 CST-AFNet 在两类场景中的平均平衡准确率都低于本文模型；ITCT/TabTransformer 在缺失场景优于部分传统卷积模型，但与本文模型相比仍存在明显差距。由此可见，本文模型的主要特点不是在某一单一场景极端冒尖，

而是在两类关键扰动条件下都保持较高水平，体现出更均衡的综合鲁棒性。




图 3.4 各模型在噪声与特征缺失场景下的平均平衡准确率比较

3.5 本章小结

本章围绕 CNN-LSTM-GRU 基线模型及其鲁棒优化过程开展实验分析。首先，普通环境测试结果表明，基线模型在干净测试集上能够取得接近满分的检测性能，说明其具备较强的基础判别能力。随后，本文通过类别比例变化、噪声扰动和特征缺失三类压力测试进一步验证模型稳定性，结果显示：类别比例变化对模型影响较小，而噪声扰动和特征缺失会明显改变模型的错误模式。

噪声扰动主要导致正常流量被误判为攻击流量，使误报率升高；特征缺失则会削弱模型对攻击模式的识别能力，使攻击召回率下降并造成漏检风险。两类退化现象说明，基线模型在普通环境中的高准确率并不能直接代表其具备真实部署所需的鲁棒性。针对这一问题，本章进一步构建了缺失鲁棒模块、降噪鲁棒模块和双鲁棒联合模块，并通过四模块软投票策略融合不同鲁棒路径的输出概率。

实验结果表明，四模块软投票模型能够综合利用 MME_DAE、FDA_NTA、AFR_ANR 和 DCRC 的互补优势，在特征缺失、噪声扰动和联合扰动条件下取得更稳定的表现。与二模块和三模块版本相比，四模块版本在平衡准确率、攻击召回率、误报率和极端场景得分等指标上更具综合优势；与若干 TensorFlow/Keras 对照模型相比，本文模型在缺失场景下表现尤其突出。上述结论为下一章进一步从四模块机制中凝练轻量化单模块结构提供了实验依据。

4 基于单模型结构的鲁棒性改进

4.1 引言

本文模型能够取得上述结果，根本原因在于它并非依赖单一增强机制，而是通过多种互补策略构成鲁棒闭环。其一，MME_DAE 通过联合利用缺失掩码和重建分支，减轻关键字段缺失造成的信息断裂；其二，FDA_NTA 通过联合扰动增强训练，使模型在训练阶段就充分暴露于多种异常输入，提升了决策边界的平滑性；其三，AFR_ANR 通过双门控机制自适应地重加权特征，降低了受噪声污染维度和无效维度对分类器的干扰；其四，DCRC 通过一致性约束缩小干净样本与受扰样本在表示空间中的偏移，使模型更不容易因局部输入变形而发生判别翻转。

此外，四模块软投票集成策略显著降低了单一模块在局部场景下失效的风险。例如，MME_DAE 在联合扰动中的平均增益虽不如 AFR_ANR 和 FDA_NTA 显著，但它在缺失恢复方面仍能提供有价值的补偿；DCRC 的平均绝对增益不是最高，却有助于提高极端场景下的稳定性。因此，本文模型的优势来自结构多样性与决策融合，而不是某一个局部技巧本身。四模块软投票更适合作为鲁棒机制有效性的探索性验证，而下面的新增单模块需要进一步说明其从原有机制中自然演化出来的过程。

4.2 单模型改进结构设计

4.2.1 基于缺失掩码的可靠性门控结构

MR²G 模块是在四模块鲁棒优化实验之后抽象出的单模块结构。该模块认为噪声扰动与字段缺失并不总是需要被还原为某个确定的原始数值，更关键的是估计当前样本中各特征或表示维度的可信度，并在分类前对不可信信息进行抑制。

MR²G 显式使用缺失掩码 m ，与受扰输入 x_{corr} 拼接后输入可靠性估计网络。掩码的作用不是简单告诉模型哪些值为 0，而是区分真实取值为 0 和该字段不可观测两种语义，避免模型将缺失填充值误解释为正常网络行为特征。因此，MR²G 可看作 MME 中掩码感知思想，FDA_NTA 与 AFR_ANR 中门控重权思想和 DCRC 中输出一致性约束思想的单模块化。

MR²G 由编码器 $E(\cdot)$ 提取表示，再由门控分支生成可靠性向量 r 。其中 r_i 越

接近 1 表示第 i 个表示维度越可信，越接近 0 则说明该维度可能受噪声、缺失或异常波动影响，应在分类时降低权重。与直接删除特征相比，连续门控能够保留不确定特征的部分信息，减少硬阈值带来的判别损失。

若采用残差补偿分支， MR^2G 可进一步生成 x 的变化量或 h 的变化量，用于对受扰表示进行小幅度补偿。 MR^2G 以二分类交叉熵 L_{cls} 保证入侵检测主任务，同时可引入一致性约束 L_{cons} ，使同一样本在干净输入与受扰输入下的预测或中间表示保持接近；还可加入门控正则 L_{gate} ，避免门控全部打开或全部关闭。其综合损失可写为：

$$L = L_{cls} + \lambda_c L_{cons} + \lambda_g L_{gate}。 \quad (4.2.1)$$

该目标函数与本文前文去噪自编码和一致性正则思想相衔接^{[6][7]}， MR^2G 模块把掩码感知、残差/表示补偿、可靠性门控和一致性训练统一为一个可训练模块，证明多模型软投票中的部分鲁棒机制可以被压缩为单模型结构；其不足在于可靠性依据主要来自输入退化和掩码信息，缺少正常/攻击类别参照。

4.2.2 基于类别原型的可靠性门控结构

本文在 MR^2G 模块实验基础上提出 PGRG 模块。 PGRG 的目标是在单一模块中引入正常/攻击类别原型、缺失掩码和可靠性门控，使模型不再依赖多个子模型投票，而是通过一个端到端结构完成受扰输入下的入侵检测。

由于受扰样本的真实原始值通常不可观测，如果直接输出所谓修复值，容易被误解为还原了真实物理特征；同时，在入侵检测任务中，过强的修复还可能把攻击样本拉向正常原型，从而削弱攻击证据并增加漏检风险。因此， PGRG 将“修复”改为“表示空间可靠性门控”：模块只判断哪些表示维度更可信、样本更接近正常还是攻击，而不声称恢复原始输入。

设受扰输入为 x_{corr} ， $x_{corr} \in R^{93}$ ，缺失掩码为 m ， $m \in \{0,1\}^{93}$ 。 PGRG 首先将二者拼接后送入编码器 $E(\cdot)$ ，得到样本表示 h ：

$$h = E([x_{corr}, m])。 \quad (4.2.2)$$

在训练阶段分别根据正常样本和攻击样本的编码表示计算类别原型 c_N 与 c_A 。对于当前样本，模块计算其到两类原型的距离：

$$d_N = \|h - c_N\|_2, \quad (4.2.3)$$

$$d_A = \|h - c_A\|_2, \quad (4.2.4)$$

$$d_p = [d_N, d_A, d_N - d_A]。 \quad (4.2.5)$$

式中 d_N 和 d_A 分别描述样本与正常行为原型、攻击行为原型之间的偏离程度。若样本在强噪声或特征缺失条件下仍明显靠近攻击原型，则模型应保留其攻击证据；若样本只是正常流量受到噪声污染，则模型可以通过可靠性门控降低不可信维度的影响。

随后，PGRG 基于样本表示、缺失掩码和原型偏离信息生成可靠性门控 r ：

$$r = \sigma(MLP([h, m, d_p]))， \quad (4.2.6)$$

$$h^* = r \odot h， \quad (4.2.7)$$

$$\hat{y} = C\left(\left[h^*, d_p, r\right]\right)。 \quad (4.2.8)$$

式中 r 表示各表示维度的可信程度， h^* 为门控后的鲁棒表示， $C(\cdot)$ 为分类头。该结构与 MR²G 的主要差别在于：MR²G 更偏向“掩码引导的特征修复”，核心是生成修正后的输入或残差补偿；PGRG 则偏向“原型引导的判别门控”，核心是利用类别原型距离保留攻击证据、抑制不可靠表示，并避免对原始特征作不可验证的数值还原。

PGRG 的训练目标由分类损失、原型约束、一致性约束和门控正则共同组成：

$$L = L_{cls} + \lambda_p L_{proto} + \lambda_c L_{cons} + \lambda_g L_{gate}。 \quad (4.2.9)$$

式中 L_{cls} 使用二分类交叉熵保证入侵检测性能； L_{proto} 使样本表示更接近其真实类别原型并远离另一类原型，可采用 margin 形式约束 $d_{same} + \gamma < d_{diff}$ ； L_{cons} 约束同一样本在干净输入和受扰输入下的预测保持一致； L_{gate} 用于防止门控全部打开或全部关闭，使模块真正发挥可靠性选择作用。通过该设计，PGRG 将原四模块中有效的鲁棒思想压缩到一个新的端到端模块中，同时引入类别原型作为判别参照系，从而增强模型在噪声、缺失和联合扰动条件下区分“输入退化”与“攻击异常”的能力。

因此，本文将四模块软投票模型作为验证不同鲁棒机制有效性的探索性对照，将 PGRG 作为后续分析中的主要改进模型。其改进点不在于简单叠加多个已有

模块，而在于把正常/攻击原型偏离、缺失掩码和可靠性门控统一到单一判别结构中。

4.2.3 单鲁棒模型设计思路

第三章中的四种鲁棒性增强方案能够在噪声扰动和特征缺失条件下改善模型性能，但软投票模型需要同时训练和调用多个子模型，测试时间和部署复杂度相对较高。为了降低模型推理开销，本文在第四章中进一步尝试将多方案集成思路简化为单模型结构，使模型能够在一次前向传播中完成特征提取、可靠性判断和最终分类。

在单模型结构设计中，本文首先考虑特征缺失对模型输入的影响。由于缺失位置本身能够反映输入数据的不完整程度，因此 MR^2G 将缺失掩码作为辅助信息引入模型，使网络在学习流量特征的同时感知哪些特征维度可能不可靠。该设计的重点不是恢复真实缺失值，而是利用掩码信息调节中间表示，从而降低缺失特征对分类结果的影响。

在此基础上，本文进一步设计 $PGRG$ ，引入正常类和攻击类的类别原型作为判别参照。与仅根据缺失掩码判断特征可靠性不同， $PGRG$ 同时考虑样本表示与类别原型之间的距离关系，使模型在输入受扰时仍能保留与攻击类别相关的判别信息。通过这种方式， $PGRG$ 尝试在不增加过多参数量的前提下，提高模型在噪声、缺失和联合扰动条件下的稳定性。

进一步地， $PGRG+$ 可看作 $PGRG$ 的增强版本。它将单一正常/攻击均值原型扩展为每类多个原型，引入局部异常 Top-K 摘要和全局可学习特征门控，以适应 IoT 流量中可能存在的类内多模态结构。 MR^2G 解决“多模型集成能否压缩为单模型”的问题， $PGRG$ 则将上述改进统一为正式的新型原型引导可靠性门控模块。

表 4.1 MR^2G 到 $PGRG+$ 的模块对比

模块	可靠性依据	是否修复原始特征	是否使用类别原型	作用定位
MR^2G	受扰特征与观测掩码	是/可选	否	初始单模块压缩尝试
$PGRG$	表示特征与观测掩码 与正常/攻击原型	否	是	正式的原型引导可靠性门控模块
$PGRG+$	多原型与局部异常摘要 与全局门控	否	是，多原型	面向复杂流量多模态结构的增强版本

因此，本文第四章的重点并不是提出多个相互独立的新模块，而是在第三章多方案对比实验的基础上，进一步探索一种更适合轻量化推理的单模型改进结构。后续实验将从联合扰动性能、参数量、测试时间和本地推理效果等方面，对 MR²G 和 PGRG 进行比较分析。

综上，本文以四模块软投票实验为机制验证基础，逐步完成从多模型集成到单模块可靠性建模、从输入修复到表示门控、从退化感知到原型判别参照的改进。

4.3 实验结果及分析

4.3.1 实验设置

本章实验沿用第三章相同的 Edge-IIoTset 数据划分、特征选择和标准化结果，以保证 MR²G、PGRG 及 PGRG+扩展对照与四模块软投票模型之间的比较只反映模块结构差异，而不受数据处理差异影响。输入特征维度仍为 93，训练集、验证集和测试集比例仍为 7:1:2，分类阈值以 0.5 为初值，并在新增模块实验中结合验证集结果进行统一评估。

表 4.1 新模块实验参数设置

训练参数	参数值
数据协议	沿用第三章训练/验证/测试划分、93 维特征和训练集拟合的标准化参数
比较模型	四模块软投票、MR ² G、PGRG、PGRG+
训练轮数	12
批处理大小	32
优化器	Adam
联合扰动评估设置	与第三章四模块软投票模型相同，覆盖低缺失高噪声、中高缺失和高缺失高噪声场景
MR ² G 关键参数	瓶颈维度 64，重构损失权重 0.2，一致性损失权重 0.25，门控稀疏权重 0.01
PGRG 关键参数	原型间隔损失权重 0.15，一致性损失权重 0.25，门控正则权重 0.01，间隔 margin=0.5，门控隐层维度 256，原型上下文维度 32
PGRG+增强参数	每类 3 个原型，启用全局可学习特征门控，局部异常摘要 Top-K 比例为 0.2
回调策略	ModelCheckpoint、EarlyStopping 和 ReduceLROnPlateau；以验证集损失或 AUC 作为监控指标

如表 4.1 所示，MR²G、PGRG 和 PGRG+均采用单模型端到端训练方式，训练阶段动态构造特征缺失与高斯噪声联合扰动，验证阶段使用固定扰动强度检查

模型稳定性。其中，MR²G 模块侧重掩码引导的残差重构与可靠性门控，PGRG 模块进一步引入正常/攻击类别原型作为判别参照，PGRG+模块则作为多原型和局部门控增强对照。

表 4.2 实验硬件信息

实验环境	
框架	TensorFlow/Keras 2.20.0
操作系统	Windows11 本地 Anaconda 环境
Python 版本	3.12.13
CUDA 版本	13.1
内存	32GB
GPU	Nvidia RTX 4070 GPU 12GB
CPU	Intel(R) Core(TM) i7-12700KF (3.60 GHz)

如表 4.2 所示，本章实验硬件与软件环境与第三章保持一致。为保证实验可复现性，本章新增模块只改变可靠性门控、原型参照和单模块压缩方式，其他训练环境与基础数据协议保持不变。

4.3.2 新模块与四模块软投票模型的性能对比实验

为进一步验证新增模块是否能够作为本文的集轻量化改进方案，本文基于最新训练结果，将 MR²G、PGRG 与 PGRG+三个单模块同四模块软投票模型置于完全一致的联合扰动评估协议下进行比较。该比较不再只关注单一精度指标，而是同时考察检测性能、模块数量、参数量、训练开销和测试时间，从而判断新增模块是否具备替代或补充四模块集成模型的实际价值。




图 4.1 三个新模块与四模块软投票模型的综合性能均值对比




图 4.2 联合扰动条件下平衡准确率变化曲线




图 4.3 联合扰动条件下攻击召回率变化曲线

从上图可以看出，PGRG 在三个新增单模块中表现最为均衡，其联合扰动平衡准确率为 99.709%，平衡准确率为 99.635%，均高于四模块软投票模型的 99.484% 和 99.345%；同时，PGRG 的精确率、F1、Macro-F1 与 ROC-AUC 也均优于四模块软投票。MR²G 的平衡准确率为 99.413%，同样略高于四模块软投票；PGRG+ 的攻击召回率达到 99.494%，在三个新模块中最高，说明其在攻击样本检出方面具有更强倾向。由此可见，MR²G、PGRG 与 PGRG+ 并非简单增加模块名称，而是在单模块结构下保留了对联合扰动的鲁棒检测能力，其中 PGRG 更适合作为综合性能最优的新增主模块。

4.3.3 新模块与四模块软投票模型的参数对比

从资源开销看，四模块软投票需要依次调用四个成员模型，平均测试时间为 690.450 秒；MR²G、PGRG 与 PGRG+ 的平均测试时间分别为 142.066 秒、142.062 秒和 172.067 秒，较四模块软投票分别减少约 79.42%、79.42% 和 75.08%。其中，MR²G 参数量为 134907，PGRG 参数量为 226718，PGRG+ 参数量为 226875。虽然 PGRG 与 PGRG+ 的参数规模高于 MR²G，但仍保持单模型端到端推理形式，

避免了四模块软投票多模型顺序调用带来的部署复杂度。

表 4.3 三个新模块与四模块软投票模型的资源开销对比

模型	模块数	参数量	训练时间/s	平均测试时间/s	测试时间降幅
四模块 软投票	4	-	-	690.450	-
MR ² G	1	134907	4414.371	142.066	79.42%
PGRG	1	226718	6858.800	142.062	79.42%
PGRG+	1	226875	5786.510	172.067	75.08%




图 4.4 三个新模块与四模块软投票模型的平均测试时间对比




图 4.5 MR²G、PGRG 与 PGRG+单模块参数量对比

综合上述结果，MR²G 可以被理解为对“掩码感知、残差重构与可靠性门控”的轻量化压缩，其优势在于以较少参数获得接近甚至超过四模块软投票的平衡准确率；PGRG 则把正常/攻击类别原型距离、缺失掩码和可靠性门控统一到单一判别结构中，在综合检测性能与测试时间之间取得最优平衡；PGRG+进一步引入多

原型和局部可靠性增强，虽然综合精度略低于 PGRG，但在攻击召回率上达到最高。

由此，本文将四模块软投票模型作为鲁棒机制有效性的探索性集成验证。综合性能和资源开销来看，PGRG 在联合扰动条件下取得了较好的平衡，因此本文将作为主要改进模型进行后续分析。PGRG+ 虽然在个别指标上有所提升，但其测试时间和资源开销增加较明显，本文不将其作为最终模型。

4.3.4 MR²G 与 PGRG 的内部机制对比

为避免仅依靠最终平均指标说明新增模块有效，本文进一步针对 PGRG 与 PGRG+的内部机制开展机制验证。该实验仍沿用前文联合扰动评估协议，重点观察类别原型、局部异常摘要、全局特征门控和可靠性门控对检测结果的作用。内部机制实验的关键设置如表 4.4 所示。

表 4.4 PGRG 内部机制实验关键设置

机制或实验项	具体设置	验证目的
联合扰动训练	训练阶段动态采样特征缺失率 0.10—0.50，并动态采样噪声标准差 0.05—0.35。	模拟端侧部署中噪声与字段缺失同时出现的输入退化。
多类别原型	正常与攻击每类设置 3 个训练集原型，PGRG+使用多原型结构。	检验模型能否刻画物联网流量的类内多模态结构。
局部异常摘要	统计原型偏离最大的前 20%特征，形成局部异常摘要。	观察攻击线索是否集中在少数关键字段，并增强局部异常感知。
全局可学习特征门控	在样本级可靠性门控之外加入全局特征门控，并与观测掩码共同作用。	判断模型能否学习总体更稳定、更有判别力的特征维度。
原型与一致性约束	原型约束权重为 0.15，一致性约束权重为 0.25，门控正则权重为 0.01，原型间隔为 0.50。	约束表示更接近真实类别原型，同时降低受扰输入导致的预测翻转。
门控结构参数	可靠性门控隐层维度为 256，原型摘要向量维度为 32。	在保持单模型结构的同时保留足够的机制表达能力。

从内部机制对照角度看，PGRG 的优势并不只来自参数量增加，而是来自“类别参照—可靠性判断—门控抑制”三者的协同。PGRG+进一步加入多原型、局部

异常摘要与全局特征门控后，攻击召回率达到 99.494%，在三个新增模块中最高，说明多原型和局部异常摘要更有利于保留攻击证据；而 PGRG 的平均平衡准确率达到 99.635%，说明单一原型引导门控结构已经能够在整体鲁棒性上取得更均衡的结果。

表 4.5 新模块内部机制实验现象与作用解释

内部机制	实验现象	作用解释
类别原型参照	PGRG 的联合扰动平均平衡准确率为 99.635%，高于四模块软投票的 99.345%，也高于 MR ² G 的 99.413%。	正常/攻击原型为可靠性判断提供类别参照，使模型不只判断输入是否受扰，还判断样本更接近正常模式还是攻击模式。
可靠性门控	PGRG 平均测试时间为 142.062 秒，较四模块软投票减少约 79.42%，同时保持更高综合性能。	门控在单模型内部抑制不可信维度，避免四个成员模型顺序调用带来的推理开销。
多原型与局部异常摘要	PGRG+的攻击召回率达到 99.494%，在三个新增模块中最高。	多原型结构与局部 Top-K 偏离摘要更容易保留攻击样本中的局部异常证据，因此对攻击检出更敏感。
不恢复原始特征值	PGRG 与 PGRG+均只在表示空间中进行门控，不输出所谓“修复后的真实特征”。	避免把攻击样本过度拉向正常分布，降低“修复值不等于真实值”的解释风险。
单模块部署形式	MR ² G、PGRG 与 PGRG+均为单模型端到端推理结构。	在保留鲁棒机制的同时减少部署复杂度，为后续端侧落地提供更直接的结构基础。

综上，新增模块的内部机制实验进一步说明：PGRG 不是对四模块软投票结果的简单重复，而是把多模块中被验证有效的缺失感知、原型判别、可靠性门控和一致性约束压缩到单一判别结构中。PGRG 更适合作为本文的单模型改进结构，而 PGRG+作为面向高攻击召回需求的增强版本没有必要性，最终决定舍弃。

4.3.5 本地推理部署可行性分析

在完成 MR²G 与 PGRG 模块的结构压缩和性能验证之后，本文进一步设计了端侧推理部署脚本，用于验证新增模块在实际部署入口下的可运行性与推理效率。部署脚本采用本地 Web 可视化方式封装模型推理流程，界面中可以选择运行 MR²G、PGRG 或同时运行两个模型，并可配置结果根目录、模型部署目录、

权重文件路径、分类阈值、最大读取样本数、模拟特征缺失率、模拟噪声标准差和随机种子等参数。该设计使训练阶段的模型结果能够被统一接入到端侧推理流程中，避免只停留在离线实验指标层面。

端部署流程主要包括以下步骤：读取部署目录中的模型结构、权重文件以及
与训练阶段一致的预处理信息；之后，对输入样本执行特征对齐、标准化和维度
重构，保证端侧输入与训练输入格式一致，然后，根据可视化参数生成缺失掩码
和噪声扰动，用于模拟物联网采集端可能出现的字段缺失与传感噪声。接着，分
别调用 MR²G 与 PGRG 的推理函数，输出攻击概率、二分类标签和可靠性门控
均值。最后，对带标签样本进行临时评估，并统计平均单样本推理耗时。该流程
将前文提出的可靠性门控思想转化为可交互的端侧推理入口。



图 4.6 MR²G 与 PGRG 端侧推理汇总界面

从图 4.6 可以看出，部署界面能够在同一入口下完成两个模型的端侧推理，并给出样本数、预测攻击数量、平均攻击概率、平均可靠性门控和平均推理耗时等汇总信息。在最大读取样本数为 1000、分类阈值为 0.5 的设置下，MR²G 与 PGRG 均预测出 299 条攻击样本，平均攻击概率均为 29.9%，说明两个模型在当前端侧样本上的最终分类输出保持一致。

而 MR²G 的平均单样本推理耗时为 0.367ms，PGRG 的平均单样本推理耗时为 0.411ms。PGRG 由于需要引入原型距离和可靠性门控计算，耗时略高于 MR²G，但两者均处于亚毫秒级推理范围，说明新增模块具备较好的端侧实时推理潜力。MR²G 的可靠性门控均值为 0.9815，表示在当前扰动设置下多数表示维度被保留；

PGRG 的可靠性门控均值为 0.0313，体现出原型引导门控对表示维度的选择更为保守。由于两类门控的定义和作用位置不同，门控均值主要用于解释各自模型内部的可靠性选择强度，而不应被简单视为两个模型优劣的直接比较。

在带标签数据上的临时评估中，两个模型的准确率、平衡准确率、精确率、攻击召回率和 F1 均达到 1.000，说明部署入口在样本读取、预处理、权重加载和阈值判定等环节没有破坏前文离线实验得到的判别能力。与第五章前文的平均测试时间结果相结合可以看出，MR²G 更适合作为资源更受限场景下的轻量化端侧方案，PGRG 则在保持较低推理开销的同时提供了更明确的类别原型参照和可靠性解释能力。




图 4.7 端侧推理预测数量与平均耗时可视化

图 4.7 进一步给出了端侧推理过程中的攻击概率曲线、正常/攻击预测数量柱状图和平均推理耗时柱状图。两个模型的预测数量分布完全一致，均表现为约 299 条攻击样本和 701 条正常样本；平均推理耗时柱状图则显示 MR²G 略快于 PGRG。这与两种模块的结构差异相一致：MR²G 主要依赖掩码引导的可靠性表示门控，推理链路较短；PGRG 在此基础上增加了原型偏离信息，因此牺牲少量时间换取更强的判别解释能力。

综上，本节端部署实验说明，MR²G 与 PGRG 模块不仅能够在离线联合扰动评估中保持较高检测性能，也能够被封装为可交互、可配置、可统计耗时的端侧推理脚本。当前部署实验属于本地端侧原型验证，重点验证模型加载、数据预处理、扰动模拟、推理输出和可视化统计等关键环节的连通性。后续若进一步部署到真实 IoT 网关或边缘计算板卡，可在此基础上将模型转换为 TensorFlowLite 或

ONNX 格式，并将特征顺序、标准化参数和分类阈值一并固化到部署包中，从而形成更加完整的轻量化物联网入侵检测端侧应用。

4.4 本章小结

本章在四模块软投票模型的基础上，进一步讨论了鲁棒机制向单模块结构压缩与凝练的过程。首先，本章分析了四模块模型性能提升的来源，指出其优势并非来自单一技巧，而是来自缺失感知、联合增强训练、可靠性门控和一致性约束等机制的互补配合。四模块软投票能够有效降低单一模块在局部扰动场景中失效的风险，但同时也存在推理链路较长和部署复杂度较高的问题。

针对上述问题，本章提出从四模块到 MR^2G 再到 $PGRG$ 的思路。 MR^2G 的设计目的是在单模型中引入缺失掩码信息，使模型能够感知输入特征的完整程度。相比四方案软投票模型，该结构减少了多模型集成带来的推理开销，用较低参数量实现对受扰输入的稳定表示；在此基础上， $PGRG$ 进一步引入正常/攻击类别原型，在 MR^2G 的基础上进一步加入类别原型信息。类别原型由训练集中正常样本和攻击样本的表示均值计算得到，用于提供一个简单的类别参照，使模型在受扰输入下仍能利用样本与两类中心之间的距离关系进行判断，从而避免直接恢复不可观测原始特征值，并增强模型区分“输入退化”和“真实攻击异常”的能力。

实验结果表明， $PGRG$ 在联合扰动平均性能和部署效率之间取得了较好的平衡，其平均测试时间相比四模块软投票明显下降，同时仍能保持较高的平衡准确率和综合检测指标。端侧推理实验进一步说明， MR^2G 和 $PGRG$ 均能够被封装为可交互、可配置和可统计耗时的本地推理脚本，具备进一步迁移到 IoT 网关或边缘设备的可行性。综上，本章完成了从多模块鲁棒验证到轻量化单模块改进的过渡。

5 总结与展望

5.1 工作总结

本文围绕物联网入侵检测模型在噪声扰动与特征缺失环境下性能不稳定的问题，构建了以压力测试为起点、以多模块联合优化为主体、以统一协议横向比较为验证方式的完整研究流程。研究首先证明：CNN-LSTM-GRU 基线模型虽然在普通环境下具有接近满分的检测精度，但其性能会随着噪声强度和特征缺失率增加而明显退化。其中，噪声扰动主要导致误报增加，特征缺失主要导致攻击召回下降，这表明鲁棒性问题具有明确而差异化的退化路径。

针对上述问题，本文依次设计了缺失鲁棒模块、降噪鲁棒模块和双鲁棒联合模块，并最终构建了由 MME_DAE、FDA_NTA、AFR_ANR 与 DCRC 组成的四模块软投票集成模型。实验表明，该模型在特征缺失场景中取得了最优平均平衡准确率 99.697%，在噪声场景中也保持 99.892% 的平均平衡准确率，表现出更加均衡的综合鲁棒性。与 4 个近期对照模型的统一协议比较进一步证明，该方法在模拟噪声和特征缺失条件下具有一定稳定性。

本文主要完成了以下工作：第一，构建了 CNN-LSTM-GRU 基线模型，并通过噪声扰动和特征缺失实验分析了模型性能退化现象。第二，设计并比较了多种鲁棒性增强方案，验证了缺失掩码、噪声增强、特征重权和一致性约束对提升模型稳定性的作用。第三，在多方案实验基础上，进一步构建了 PGRG 改进模型，并从性能、参数量和测试时间角度分析了其综合表现。

在四模块软投票实验的基础上，本文进一步提出 PGRG 原型引导可靠性门控模块，并以 PGRG+ 作为其多原型增强版本。PGRG 以正常/攻击类别原型为判别参照，在不恢复原始特征值的前提下，通过原型偏离距离和缺失掩码生成可靠性门控，从表示空间抑制不可信维度并保留攻击证据。相比四模块软投票，PGRG 更强调单一模块内的机制融合；相比修复式模块，PGRG 避免了“修复值不等于真实值”的解释风险，更适合作为本文面向入侵检测鲁棒优化的新增主模块。

最新训练结果进一步验证了新增模块的有效性：在联合扰动平均性能中，PGRG 的平衡准确率高于 MR²G、PGRG+ 和四模块软投票；虽然 PGRG+ 的攻击召回率也在三个新模块中最高，但是综合考虑资源开销与性能增益，本文未将

PGRG+作为最终主模型。与此同时，PGRG 的平均测试时间由四模块软投票的 690.450 秒降至 142.062 秒，测试时间降幅约为 79.42%。因此，最终可将 PGRG 作为综合性能与部署效率更均衡的新模块改进点。同样，由于 MR²G 的参数量和平均推理时间最低，最终可将 MR²G 作为综合性能与部署效率的轻量化选择。

5.2 未来展望

本文围绕复杂输入退化条件下的物联网入侵检测鲁棒性问题开展研究，取得了一定实验效果。未来可从数据场景扩展、模型自适应、安全鲁棒性、端侧部署和可解释性等方面继续深入研究。

1) 扩展更真实的多源数据与跨场景验证。本文主要基于 Edge-IIoTset 数据集开展二分类实验，虽然能够较好模拟 IoT/IIoT 场景下的典型攻击流量，但真实工业现场还可能存在跨设备、跨协议、跨时间段和跨网关采集差异。后续研究可引入更多公开数据集和真实边缘网关日志，进一步验证模型在跨域迁移、长期运行和多类型攻击识别场景中的泛化能力，并将二分类任务扩展到多分类或分层告警任务。

2) 研究在线学习与动态自适应机制。真实物联网环境中的网络流量分布会随着设备更新、业务变化和攻击策略演化而持续漂移。未来可以在 PGRG 等原型引导模块基础上，引入增量学习、域自适应或持续学习机制，使类别原型和可靠性门控能够根据新数据动态更新，从而降低模型长期部署后的性能衰减风险。同时，还需要设计异常更新检测机制，避免攻击样本污染模型更新过程。

3) 增强对对抗样本和复合异常输入的防护能力。本文重点讨论高斯噪声、随机特征缺失及其联合扰动，但实际攻击者可能通过更隐蔽的特征篡改、规避攻击或低频慢速攻击误导检测模型。后续可结合对抗训练、异常特征约束、置信度校准和不确定性估计等方法，进一步提升模型在恶意扰动下的安全性，并评估模型在不同攻击强度、不同缺失机制和不同噪声分布下的鲁棒边界。

4) 提升模型解释性与工程可维护性。入侵检测系统不仅需要给出 Normal/Attack 判定，还需要为运维人员提供可理解的告警依据。未来可结合可靠性门控输出、原型距离、特征贡献分析和异常证据可视化，解释模型为何将某一流量为攻击或正常。进一步地，还可将模型监控、阈值管理、告警回溯和

数据漂移检测纳入完整工程流程,使鲁棒入侵检测模型从离线实验进一步走向可维护、可审计和可持续迭代的实际安全系统。

参考文献

- [1] Ferrag M A, Friha O, Hamouda D, et al. Edge-IIoTset: A new comprehensive realistic cyber security dataset of IoT and IIoT applications for centralized and federated learning[J]. IEEE Access, 2022, 10: 40281-40306.
- [2] 刘奇旭, 陈艳辉, 尼杰硕, 罗成, 柳彩云, 曹雅琴, 谭儒, 冯云, 张越. 基于机器学习的工业互联网入侵检测综述[J]. 计算机研究与发展, 2022, 59(5): 994-1014.
- [3] 蹇诗婕, 卢志刚, 杜丹, 姜波, 刘宝旭. 网络入侵检测技术综述[J]. 信息安全学报, 2020, 5(4): 96-122.
- [4] Goodfellow I, Bengio Y, Courville A. Deep learning[M]. Cambridge: MIT Press, 2016.
- [5] Ennaji S, De Gaspari F, Hitaj D, Kbidi A, Mancini L V. Adversarial challenges in network intrusion detection systems: Research insights and future prospects[EB/OL]. arXiv:2409.18736, 2024.
- [6] Tahir M, Abdullah A, Udzir N I, Kasmiran K A. A novel approach for handling missing data to enhance network intrusion detection system[J]. Cyber Security and Applications, 2025, 3: 100063.
- [7] Kilichev D, Turimov D, Kim W. Next-Generation Intrusion Detection for IoT EVCS: Integrating CNN, LSTM, and GRU Models[J]. Mathematics, 2024, 12(4): 571.
- [8] Vincent P, Larochelle H, Lajoie I, et al. Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion[J]. Journal of Machine Learning Research, 2010, 11: 3371-3408.
- [9] Tarvainen A, Valpola H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[EB/OL]. arXiv:1703.01780, 2017.
- [10] Snell J, Swersky K, Zemel R. Prototypical networks for few-shot learning[C]//Advances in Neural Information Processing Systems. 2017: 4077-4087.
- [11] Al Nuaimi T, Al Zaabi S, Alyilieli M, et al. A comparative evaluation of intrusion

- detection systems on the Edge-IIoT-2022 dataset[J]. Intelligent Systems with Applications, 2023, 20: 200298. DOI: 10.1016/j.iswa.2023.200298.
- [12] 张吕军. 基于深度迁移学习的物联网入侵检测框架[J]. 物联网技术, 2021, 11(11): 58-61.
- [13] 魏明锐. 基于可解释学习的物联网安全通用入侵检测系统[J]. 绵阳师范学院学报, 2021, 40(11): 83-89.
- [14] 吕正林, 段炼, 朱龙, 岳岩岩, 刘斌, 吴正坤. 边云协同环境下智能家居物联网入侵检测方法[J]. 移动通信, 2022(5): 106-112.
- [15] 邓华伟, 李喜旺. 基于深度学习的网络流量异常识别与检测[J]. 计算机系统应用, 2023, 32(2): 274-280.
- [16] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [17] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [18] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[EB/OL]. arXiv:1406.1078, 2014.
- [19] Huang X, Khetan A, Cvitkovic M, et al. TabTransformer: Tabular data modeling using contextual embeddings[EB/OL]. arXiv:2012.06678, 2020.
- [20] Nazre R, Budke R, Oak O, et al. A temporal convolutional network-based approach for network intrusion detection[C] 2024 International Conference on Integrated Intelligence and Communication Systems (ICIICS). IEEE, 2024: 635-640. DOI: 10.1109/ICIICS63763.2024.10860234.
- [21] Naeem A, Ahmad J, Khan M A, et al. Efficient IoT intrusion detection with an improved attention-based CNN-BiLSTM architecture[EB/OL]. arXiv:2503.19339, 2025.
- [22] Ishtiaq W, Zannat A, Parvez A H M S, et al. CST-AFNet: A dual attention-based deep learning framework for intrusion detection in IoT networks[J]. Array, 2025, 27: 100501.

- [23] Hasan T, Hossain A, Ansari M Q, et al. Enhanced intrusion detection in IIoT networks: A lightweight approach with autoencoder-based feature learning[EB/OL]. arXiv:2501.15266, 2025.
- [24] 吴维鑫, 侯会文, 石乐义. 基于深度学习和联邦学习的工控入侵检测研究[J]. 微电子学与计算机, 2024, 41(9): 22-31.
- [25] Tafreshian B, Zhang S. A defensive framework against adversarial attacks on machine learning-based network intrusion detection systems[EB/OL]. arXiv:2502.15561, 2025.
- [26] Du T, Melis L, Wang T. ReMasker: Imputing tabular data with masked autoencoding[C] Proceedings of the International Conference on Learning Representations. 2024.
- [27] Yin J, Qiao Y, Zhou Z, et al. MCM: Masked cell modeling for anomaly detection in tabular data[C] Proceedings of the International Conference on Learning Representations. 2024.
- [28] Wang F, Zhang T, Wang Y, et al. Distribution prototype diffusion learning for open-set supervised anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025.
- [29] Zhou Z, Pan Y, Wang L, et al. Pro-AD: Learning comprehensive prototypes with prototype-based constraint for multi-class unsupervised anomaly detection[EB/OL]. arXiv:2506.13097, 2025.
- [30] Alaba F A, Othman M, Hashem I A T, Alotaibi F. Internet of Things security: A survey[J]. Journal of Network and Computer Applications, 2017, 88: 10-28. DOI: 10.1016/j.jnca.2017.04.002.

致 谢

本论文是在指导教师孙轲的悉心指导下完成的。从选题确立、实验设计到论文撰写，指导教师孙轲都给予了耐心细致的帮助，使我能够在本科阶段较为系统地完成一次完整的研究训练。在论文最后检查后，孙轲老师对实验指标选择、摘要表述和参考文献规范提出了修改意见，使我对本科论文写作的完整流程有了更清晰的认识。在此谨向指导教师孙轲表示诚挚的感谢。

其次，感谢四年来所有授课老师的栽培与教诲，夯实了我的专业基础，让我能够熟练掌握相关技术与理论知识，为本次课题研究提供了坚实支撑，其中尤其感谢冷碧莹老师，正是她的耐心指导，才能让我在相关领域的难点中有所突破，对相关知识的学习更加地有热情。

也感谢朝夕相处的同学，如果没有他们在生活中的陪伴与对我的不吝帮助，我的学习与生活不会有现在这样的快乐，尤其感谢同寝室楼的王雨乐、王悦骅、赵童、杭志川、姚旭、王嘉贝、刘瑾寰，马鼎杰等同学，他们是我学业上并肩同行的伙伴，也是我生活中同甘共苦的挚友。

同时，感谢所在学院为本研究提供的中期答辩，为我的论文进行指正，也为我后期的实验提供了方向，感谢在论文写作过程中给予我建议和帮助的老师与同学。正是在不断讨论、修正和完善的过程中，本文才得以顺利完成。

最后，由衷感谢一路默默陪伴我的家人。感谢父母数十年的照料与无私付出，感念表兄弟平日里的扶持。正是平日中家人亲戚的帮助，为我的大学学习扫除了后顾之忧，让我得以沉下心钻研学习、专心完成课题研究。

毕业设计的完成不仅是本科阶段学习成果的一次总结，也让我更加深刻地认识到严谨研究态度和持续思考的重要性。

丁志成

上海大学

2026年6月1日

